UNIVERSIDAD DE LA SALLE

Facultad de Ingeniería — Departamento de Ciencias Básicas

Maestría en Inteligencia Artificial

PROYECTO INTEGRADOR DE CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

Fase 1: Planteamiento del Problema, Descripción Técnica y Análisis Exploratorio de Datos (EDA)

Entregable Técnico 1 (Ponderación: 20 %)

Estudiante:
Yerson León Montañez
yeleon36@unisalle.edu.co
Código Estudiantil: Maestría en IA

Docente Titular:
Fabián Camilo Castro Riveros
Cátedra de Ciencia de Datos
Periodo Académico: 2026-II

Bogotá D.C., Colombia
28 de octubre de 2026

Índice

1. Formulación del Problema y Objetivos del Proyecto **2**

1.1. Contextualización del Dominio e Impacto de la Solución Analítica 2

1.2. Preguntas de Investigación 2

1.2.1. Pregunta Principal 2

1.2.2. Preguntas Secundarias 2

1.3. Objetivos del Proyecto en Formato SMART 3

1.3.1. Objetivo General 3

1.3.2. Objetivos Específicos 3

2. Ficha Técnica del Dataset y Diccionario de Datos **4**

2.1. Ficha Técnica Institucional 4

2.2. Diccionario Exhaustivo de Variables 4

3. Análisis Exploratorio de Datos (EDA) Exhaustivo **5**

3.1. Diagnóstico Riguroso de Calidad de Datos 5

3.2. Detección y Tratamiento Formal de Valores Atípicos (Outliers) 6

3.3. Análisis Univariado Cuantitativo y Momentos de Forma 7

3.4. Distribución de Clases de la Variable Objetivo (`Churn`) 8

3.5. Análisis Bivariado y Correlación Numérica 8

3.6. Pruebas de Independencia χ^2 y Asociación de Variables Cualitativas 10

3.7. Interpretación y Síntesis Analítica 12

4. Conclusiones Metodológicas y Plan de Acción para la Fase 2 **13**

1. Formulación del Problema y Objetivos del Proyecto

1.1. Contextualización del Dominio e Impacto de la Solución Analítica

En la industria global de telecomunicaciones, la retención de suscriptores constituye uno de los desafíos operacionales y financieros más críticos. La pérdida no planificada de clientes (*Customer Churn*) impacta directamente en el flujo de caja recurrente (*Monthly Recurring Revenue* - MRR) e incrementa el costo marginal por cliente atendido. Múltiples investigaciones empíricas demuestran que captar un suscriptor nuevo representa un costo entre cinco y veinticinco veces superior a retener un cliente fidelizado, considerando los gastos de adquisición comercial, subsidios de infraestructura y comisiones.

Asimismo, la deserción en telecomunicaciones es un fenómeno multifactorial inducido por presiones tarifarias, calidad de conectividad, soporte posventa deficiente y la oferta de servicios suplementarios (tales como seguridad cibernética, copias de seguridad y asistencia técnica). El desarrollo de una solución basada en el ciclo completo de Ciencia de Datos y Aprendizaje Automático permite transformar registros operacionales pasivos en capacidades predictivas y prescriptivas. Al predecir con alta precisión el abandono, estimar la facturación monetaria acumulada (*Customer Lifetime Value* - LTV) y segmentar la base instalada mediante agrupamiento no supervisado, la empresa puede focalizar incentivos de retención, optimizar costos operativos y personalizar paquetes de servicio en tiempo real.

1.2. Preguntas de Investigación

1.2.1. Pregunta Principal

> **¿Cuáles son los patrones de comportamiento de consumo, características de suscripción contractual y perfiles tecnológicos que determinan de manera estadísticamente significativa la probabilidad de deserción (*Churn*) de un cliente de telecomunicaciones, y cómo pueden estructurarse en modelos predictivos y de segmentación para optimizar la retención y anticipar el valor facturado acumulado?**

1.2.2. Preguntas Secundarias

1. **Pregunta Secundaria 1 (Estructura Contractual y Financiera):** ¿En qué medida la modalidad de contrato (mensual vs. anual/bianual) y el método de facturación (electrónica con débito automático vs. cheque electrónico) condicionan la tasa de deserción del usuario?
2. **Pregunta Secundaria 2 (Servicios de Valor Agregado):** ¿Constituye la suscripción a servicios complementarios de protección y soporte (*TechSupport*, *OnlineSecurity*, *OnlineBackup*) una barrera de salida efectiva que reduce el riesgo de fuga frente a clientes con servicios puramente de conectividad?
3. **Pregunta Secundaria 3 (Modelación Continua y Relación No Lineal):** ¿Cuál es el grado de interdependencia cuantitativa entre la antigüedad del cliente (*tenure*), los cargos mensuales facturados (*MonthlyCharges*) y los cobros históricos acumulados (*TotalCharges*), y cómo puede modelarse matemáticamente para detectar anomalías y anticipar el LTV del cliente?

1.3. Objetivos del Proyecto en Formato SMART

1.3.1. Objetivo General

Desarrollar y validar un sistema analítico predictivo y prescriptivo de Ciencia de Datos para la industria de telecomunicaciones, integrando modelos de regresión regularizada para la estimación de ingresos acumulados, algoritmos supervisados de clasificación y un Perceptrón Multicapa (MLP) en PyTorch para la predicción de la deserción, complementados con segmentación no supervisada (K-Means y Jerárquico/DBSCAN) y un dashboard interactivo desplegado en la web, en el lapso académico del 20 de octubre al 28 de noviembre de 2026.

1.3.2. Objetivos Específicos

1. **Objetivo Específico 1 — EDA, Diagnóstico de Calidad y Ficha Técnica [Fase 1]:**
   S (Específico): Caracterizar estadísticamente las 21 variables del dataset de telecomunicaciones mediante métricas univariadas (momentos de forma, tendencia y dispersión), matrices de correlación bivariada, pruebas de independencia de Chi-cuadrado (χ^2) y auditoría de datos faltantes y atípicos.
   M (Medible): Procesar el 100 % de las 7,043 observaciones, cuantificar la significancia estadística (p-valor < 0.05) y el tamaño del efecto (V de Cramér) para el total de variables cualitativas.
   A (Alcanzable): Ejecutado mediante librerías científicas (`pandas`, `scipy.stats`, `seaborn`) y documentado en formato LaTeX y Jupyter Notebook reproducible.
   R (Relevante): Establece la base empírica indispensable para el tratamiento de valores nulos encubiertos y la prevención de fuga de información (*data leakage*).
   T (Temporal): Completado y entregado al 01 de noviembre de 2026.

2. **Objetivo Específico 2 — Preprocesamiento, Ingeniería de Variables y Modelos de Aprendizaje [Fases 2 y 3]:**
   S (Específico): Implementar una tubería de preprocesamiento rigurosa (imputación justificada, codificación One-Hot sin data leakage, escalado ajustado sobre entrenamiento) y entrenar modelos de regresión lineal regularizada (Ridge/Lasso), ensambles de árboles (Random Forest, XGBoost), clasificadores diversos y una red neuronal MLP en PyTorch.
   M (Medible): Superar un coeficiente de determinación $R^2 \geq 0.80$ en la estimación de cargos y alcanzar un F_1-score ≥ 0.78 junto con un *AUC-ROC* ≥ 0.84 en la clase minoritaria de deserción.
   A (Alcanzable): Respaldado en validación cruzada estratificada (*Stratified K-Fold*) y balanceo algorítmico.
   R (Relevante): Garantiza solidez metodológica y capacidad de generalización sobre datos no observados.
   T (Temporal): Implementado y optimizado entre el 03 de noviembre y el 22 de noviembre de 2026.

3. **Objetivo Específico 3 — Puesta en Producción, Interpretabilidad y Visualización Interactiva [Fase 4]:**
   S (Específico): Desplegar una aplicación web interactiva en Streamlit que integre tarjetas ejecutivas de KPI, un simulador de inferencia en tiempo real para predicción de Churn y visualización del espacio de agrupamiento de clientes asistido por análisis de componentes principales (PCA), complementado con interpretabilidad global y local mediante valores SHAP.
   M (Medible): Tiempos de respuesta de inferencia menores a 500 ms y 100 % de disponibilidad del dashboard web.

A (Alcanzable): Implementado a través de librerías nativas de Python y estructuración modular del repositorio.
R (Relevante): Facilita la toma de decisiones basada en datos por parte de directores comerciales y de fidelización.
T (Temporal): Finalizado y sustentado oralmente el 28 de noviembre de 2026.

2. Ficha Técnica del Dataset y Diccionario de Datos

2.1. Ficha Técnica Institucional

El conjunto de datos seleccionado cumple con la totalidad de los criterios restrictivos establecidos en la Sección 2 de la Guía Técnica del Proyecto Integrador: proviene de un repositorio público reconocido, no constituye un conjunto didáctico básico restringido (como Iris o Titanic), supera con holgura los 600 registros limpios (7,043 observaciones), cuenta con 21 variables mixtas (cualitativas y cuantitativas) y permite formular simultáneamente problemas de regresión, clasificación y agrupamiento.

Tabla 1: Ficha técnica del conjunto de datos.

Descriptor Metodológico	**Detalle Técnico**
Nombre del Dataset	*Telco Customer Churn (IBM Business Analytics Dataset)*
Repositorio de Origen	Kaggle Datasets / IBM Community Analytics
URL Oficial de Acceso	`https://www.kaggle.com/datasets/blastchar/telco-customer-churn`
Tipo de Licencia	Creative Commons Zero (CC0: Public Domain) / Apache License 2.0
Fecha de Extracción	28 de octubre de 2026
Formato de Almacenamiento	Comma-Separated Values (`.csv`), codificación UTF-8
Volumen del Conjunto	7,043 registros (filas) y 21 atributos (columnas)
Uso en Regresión	Estimación de `TotalCharges` o `MonthlyCharges` (Variables cuantitativas continuas)
Uso en Clasificación	Predicción del estado de deserción `Churn` (Variable categórica binaria: Sí / No)
Uso en Clustering	Segmentación no supervisada por `tenure`, consumo tarifario y tenencia de servicios

2.2. Diccionario Exhaustivo de Variables

A continuación se detalla la semántica de cada uno de los 21 campos del conjunto de datos, especificando su tipología estadística formal, rol analítico en el proyecto y rango de valores permitidos.

Tabla 2: Diccionario de datos completo y tipificación estadística.

Nombre Columna	Tipo Estadístico	Descripción Funcional en el Dominio	Valores Permitidos / Rango
`customerID`	Cualitativa Nominal	Identificador alfanumérico único por suscriptor	Formato alfanumérico (`XXXX-XXXXX`)
`gender`	Cualitativa Nominal (Binaria)	Género biológico reportado por el cliente	`Female`, `Male`
`SeniorCitizen`	Cualitativa Nominal (Binaria)	Indicador si el cliente es adulto mayor (≥ 65 años)	`0` (No), `1` (Sí)
`Partner`	Cualitativa Nominal (Binaria)	Si el suscriptor convive con cónyuge o pareja	`Yes`, `No`
`Dependents`	Cualitativa Nominal (Binaria)	Si el cliente tiene personas dependientes económicamente	`Yes`, `No`
`tenure`	Cuantitativa Discreta	Cantidad de meses de permanencia en la empresa	Enteros en $[0, 72]$
`PhoneService`	Cualitativa Nominal (Binaria)	Suscripción al servicio de telefonía fija	`Yes`, `No`
`MultipleLines`	Cualitativa Nominal	Tenencia de múltiples líneas telefónicas	`No phone service`, `No`, `Yes`
`InternetService`	Cualitativa Nominal	Proveedor de conexión a internet contratada	`DSL`, `Fiber optic`, `No`
`OnlineSecurity`	Cualitativa Nominal	Servicio de seguridad perimetral antivirus/malware	`No internet service`, `No`, `Yes`
`OnlineBackup`	Cualitativa Nominal	Almacenamiento seguro en la nube	`No internet service`, `No`, `Yes`
`DeviceProtection`	Cualitativa Nominal	Póliza de protección y reemplazo de hardware	`No internet service`, `No`, `Yes`
`TechSupport`	Cualitativa Nominal	Soporte técnico prioritario especializado	`No internet service`, `No`, `Yes`
`StreamingTV`	Cualitativa Nominal	Transmisión de televisión en línea vía internet	`No internet service`, `No`, `Yes`
`StreamingMovies`	Cualitativa Nominal	Transmisión de películas y series vía internet	`No internet service`, `No`, `Yes`
`Contract`	Cualitativa Ordinal	Duración y modalidad legal del contrato	`Month-to-month`, `One year`, `Two year`
`PaperlessBilling`	Cualitativa Nominal (Binaria)	Facturación ecológica digital en lugar de física	`Yes`, `No`
`PaymentMethod`	Cualitativa Nominal	Mecanismo de pago registrado por el usuario	`Electronic check`, `Mailed check`, `Bank transfer`, `Credit card`
`MonthlyCharges`	Cuantitativa Continua	Tarifa mensual devengada por el cliente	Real en $[18.25, 118.75]$ USD
`TotalCharges`	Cuantitativa Continua	Importe monetario total acumulado facturado	Real en $[18.80, 8684.80]$ USD
`Churn`	Cualitativa Nominal (Binaria)	**Variable Objetivo:** Abandono en el último mes	`Yes`, `No`

3. Análisis Exploratorio de Datos (EDA) Exhaustivo

3.1. Diagnóstico Riguroso de Calidad de Datos

La auditoría de integridad sobre la estructura tabular cruda evaluó duplicados, consistencia de claves primarias y presencia de nulos aparentes o encubiertos.

- **Duplicidad de Registros:** Se comprobó la unicidad de las filas. La cantidad de registros repetidos globales es 0 (0.0 %), y la clave primaria `customerID` no presenta ninguna duplicidad (7,043 identificadores unívocos).

- **Valores Faltantes Encubiertos:** De las 21 columnas, 20 presentan un 0.0 % estricto de valores faltantes. No obstante, una inspección de tipos reveló que `TotalCharges` fue leída inicialmente como tipo `object` (cadena de texto). La inspección profunda detectó exactamente 11 registros donde el valor registrado correspondía a un espacio en blanco (`' '`).
- **Diagnóstico del Mecanismo de Falta (MCAR vs. MAR vs. MNAR):**
  Al cruzar los 11 registros donde `TotalCharges` está en blanco con las demás características, se evidenció que en el 100 % de los casos (11/11), la variable `tenure` es idénticamente igual a 0. Corresponden a clientes en su primer ciclo de facturación que aún no han recibido su cobro histórico.
  Por tanto, el mecanismo de falta no es *Missing Completely at Random* (MCAR) ni *Missing Not at Random* (MNAR), sino estrictamente **Missing at Random (MAR)**, pues la probabilidad de ausencia está matemáticamente explicada por otra variable completamente observada (`tenure = 0`). Esto justifica teóricamente que en la Fase 2 dichos valores no deben descartarse, sino imputarse deterministicamente a cero (`TotalCharges = 0.0`).

3.2. Detección y Tratamiento Formal de Valores Atípicos (Outliers)

Para evaluar la existencia de valores atípicos en las tres dimensiones continuas (`tenure`, `MonthlyCharges` y `TotalCharges`), se implementaron dos criterios matemáticos formales:

1. **Criterio del Rango Intercuartílico de Tukey (IQR):**

$$IQR = Q_3 - Q_1, \quad L_{inf} = Q_1 - 1.5 \cdot IQR, \quad L_{sup} = Q_3 + 1.5 \cdot IQR \tag{1}$$

2. **Criterio de Estandarización de Puntuación Z (Z-Score):**

$$Z_i = \frac{x_i - \mu}{\sigma}, \quad \text{Atípico si } |Z_i| > 3 \tag{2}$$

Tabla 3: Diagnóstico cuantitativo de valores atípicos mediante criterios IQR y Z-score.

Variable	L_{inf} **(IQR)**	L_{sup} **(IQR)**	**Atípicos IQR** (n)	**% IQR**	**Atípicos** $\lvert Z\rvert > 3$ (n)	**%** $\lvert Z\rvert > 3$
`tenure`	−60.00	124.00	0	0.000 %	0	0.000 %
`MonthlyCharges`	−46.02	171.38	0	0.000 %	0	0.000 %
`TotalCharges`	−4688.48	8884.67	0	0.000 %	0	0.000 %

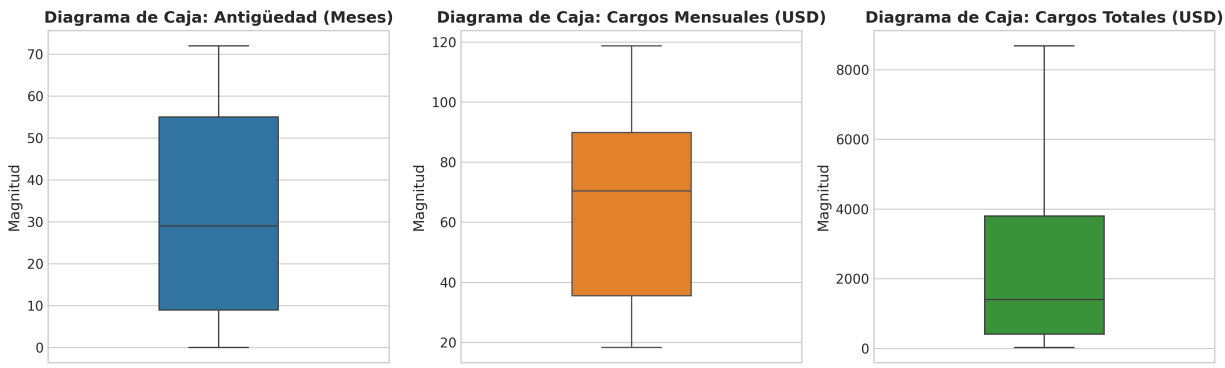


Figura 1: Diagramas de caja (*boxplots*) para las variables cuantitativas continuas.

Interpretación: Como se aprecia en la Tabla 3 y en la Figura 1, ninguna de las tres variables continuas presenta observaciones fuera de los límites de Tukey ni fuera del intervalo de tres desviaciones estándar. Esto ocurre porque `tenure` está naturalmente acotada por las políticas de retención (0 a 72 meses), los cobros mensuales corresponden a planes tarifarios estructurados ($\approx$ \$18 a \$118) y los cobros totales están acotados por el producto de ambas dimensiones.

3.3. Análisis Univariado Cuantitativo y Momentos de Forma

Se estimaron los cuatro momentos estadísticos (media, varianza/desviación, asimetría y curtosis) para las variables continuas.

- **Asimetría de Fisher-Pearson (g_1):**

$$g_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{\left[\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right]^{3/2}} \tag{3}$$

- **Exceso de Curtosis de Fisher (g_2):**

$$g_2 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4}{\left[\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right]^{2}} - 3 \tag{4}$$

Tabla 4: Medidas univariadas de tendencia central, dispersión y momentos de forma.

Variable	Media	Mediana	Desv. Est.	IQR	Mínimo	Máximo	Asimetría (g_1)	Curtosis (g_2)
`tenure`	32.37	29.00	24.56	46.00	0.00	72.00	+0.2395	−1.3874
`MonthlyCharges`	64.76	70.35	30.09	54.35	18.25	118.75	−0.2205	−1.2573
`TotalCharges`	2283.30	1397.48	2266.77	3393.29	18.80	8684.80	+0.9616	−0.2318

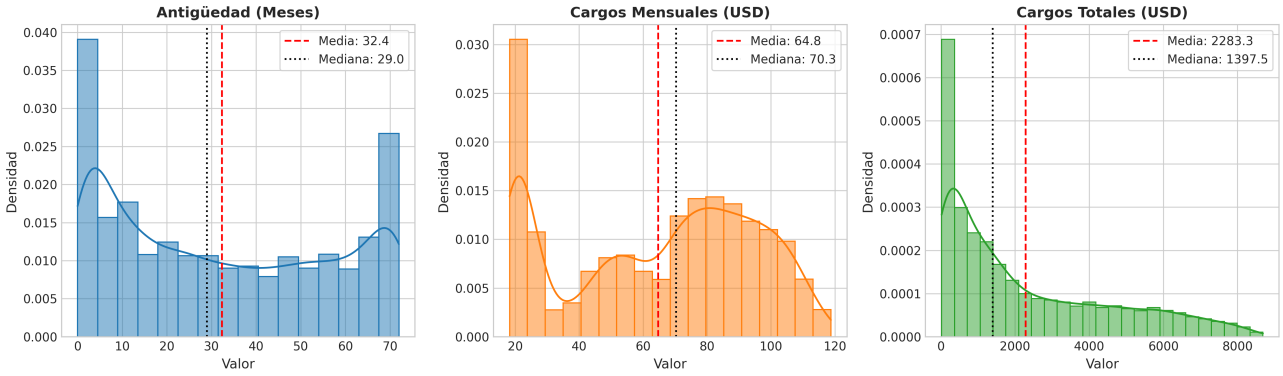


Figura 2: Distribuciones univariadas con estimación de densidad por kernel (KDE), medias y medianas.

Diagnóstico Estadístico de las Distribuciones:

- **Antigüedad (`tenure`):** Presenta una distribución platicúrtica ($g_2 = -1.3874$) fuertemente bimodal (Figura 2). Existen dos concentraciones poblacionales extremas: suscriptores en su primer año (< 12 meses) y clientes de lealtad extrema (> 60 meses).

- **Cargos Mensuales (`MonthlyCharges`):** Muestra igualmente una morfología platicúrtica bimodal ($g_2 = -1.2573$), con un primer pico en planes básicos de solo telefonía ($\approx \$20$) y un segundo pico amplio en usuarios con planes empaquetados de banda ancha y streaming ($\$70 - \$90$).
- **Cargos Totales (`TotalCharges`):** Evidencia una marcada asimetría positiva a la derecha ($g_1 = +0.9616$), donde la media ($2283.30) supera drásticamente a la mediana ($1397.48). Esto sugiere que en la Fase 2 convendrá ensayar transformaciones logarítmicas o Box-Cox para estabilizar la varianza en los modelos lineales.

3.4. Distribución de Clases de la Variable Objetivo (`Churn`)

La variable objetivo `Churn` exhibe $5,174$ registros para la clase negativa (`No`, $73.46\,\%$) y $1,869$ registros para la clase positiva (`Yes`, $26.54\,\%$). Se identifica un **desbalance moderado** (proporción aproximada $3:1$). Esto exige implementar en la Fase 2 y Fase 3 técnicas de muestreo estratificado (*Stratified Split*), optimización basada en F_1-score / *AUC-ROC*, y ajuste de pesos de clase (`class_weight='balanced'`) para evitar sesgos hacia la clase mayoritaria.

3.5. Análisis Bivariado y Correlación Numérica

Se estimaron los coeficientes de correlación paramétrica lineal de Pearson (r) y no paramétrica monótona de Spearman (ρ) entre las variables cuantitativas continuas:

Tabla 5: Matrices de correlación de Pearson (triángulo inferior/izquierda) y Spearman (triángulo superior/derecha).

Métrica / Variable	`tenure`	`MonthlyCharges`	`TotalCharges`
Pearson (r):			
`tenure`	1.0000	0.2479	0.8259
`MonthlyCharges`	0.2479	1.0000	0.6511
`TotalCharges`	0.8259	0.6511	1.0000
Spearman (ρ):			
`tenure`	1.0000	0.2764	0.8892
`MonthlyCharges`	0.2764	1.0000	0.6383
`TotalCharges`	0.8892	0.6383	1.0000

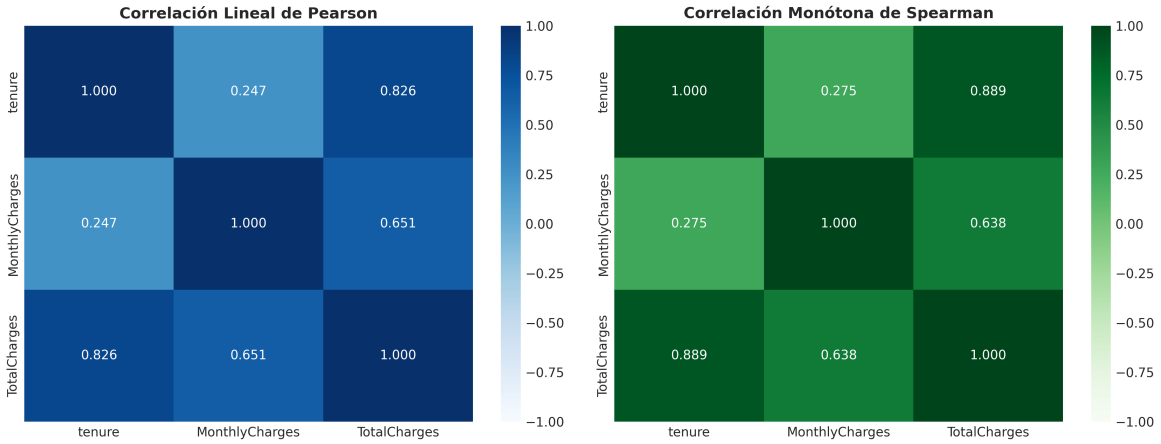


Figura 3: Mapas de calor de las correlaciones numéricas de Pearson y Spearman.

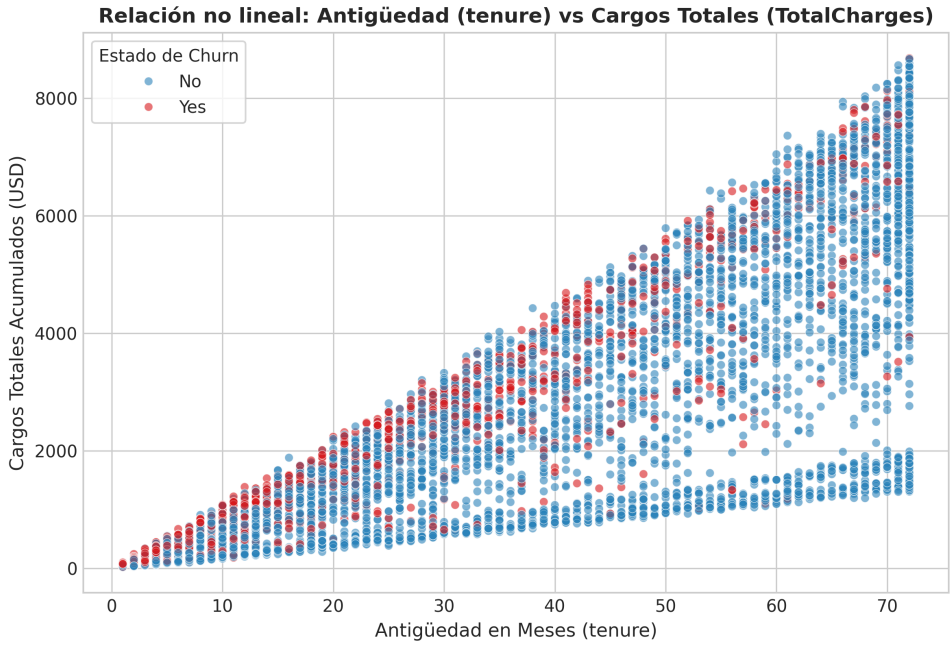


Figura 4: Diagrama de dispersión bivariado `tenure` vs. `TotalCharges` categorizado por deserción.

Hallazgos Bivariados Clave:

1. Existe una asociación monótona casi perfecta entre la antigüedad y los cargos totales ($\rho = 0.8892$), superando a la correlación lineal de Pearson ($r = 0.8259$). Como ilustra la Figura 4, la dispersión adopta una estructura de embudo con pendientes diferenciadas según la tarifa mensual.

2. Los clientes desertores (*puntos rojos en la Figura 4*) se concentran masivamente en las franjas de baja antigüedad ($0 - 15$ meses), confirmando que el mayor riesgo de abandono se produce durante el primer año de contrato.

3.6. Pruebas de Independencia χ^2 y Asociación de Variables Cualitativas

Para evaluar la relación entre cada variable categórica y la variable objetivo `Churn`, se construyeron tablas de contingencia y se computaron las pruebas de independencia de Chi-cuadrado (χ^2), así como el tamaño del efecto mediante la V de Cramér:

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{(O_{ij}-E_{ij})^2}{E_{ij}}, \qquad V = \sqrt{\frac{\chi^2}{n\cdot \min(r-1,c-1)}} \tag{5}$$

Tabla 6: Pruebas de independencia de Chi-cuadrado y coeficiente V de Cramér frente a `Churn`.

Variable Categórica	**Estadístico χ^2**	**Grados Lib. (df)**	**p-valor**	**V de Cramér**	**Intensidad Asociación**
`Contract`	1184.60	2	5.86×10^{-258}	0.4101	**Fuerte** ($V > 0.30$)
`OnlineSecurity`	850.00	2	2.66×10^{-185}	0.3474	**Fuerte** ($V > 0.30$)
`TechSupport`	828.20	2	1.44×10^{-180}	0.3429	**Fuerte** ($V > 0.30$)
`InternetService`	732.31	2	9.57×10^{-160}	0.3225	**Fuerte** ($V > 0.30$)
`PaymentMethod`	648.14	3	3.68×10^{-140}	0.3034	**Fuerte** ($V > 0.30$)
`OnlineBackup`	601.81	2	2.08×10^{-131}	0.2923	Moderada ($0.15 \leq V \leq 0.30$)
`DeviceProtection`	558.42	2	5.51×10^{-122}	0.2816	Moderada ($0.15 \leq V \leq 0.30$)
`StreamingMovies`	375.66	2	2.67×10^{-82}	0.2310	Moderada ($0.15 \leq V \leq 0.30$)
`StreamingTV`	374.20	2	5.53×10^{-82}	0.2305	Moderada ($0.15 \leq V \leq 0.30$)
`PaperlessBilling`	258.28	1	4.07×10^{-58}	0.1915	Moderada ($0.15 \leq V \leq 0.30$)
`Dependents`	189.13	1	4.92×10^{-43}	0.1639	Moderada ($0.15 \leq V \leq 0.30$)
`SeniorCitizen`	159.43	1	1.51×10^{-36}	0.1505	Moderada ($0.15 \leq V \leq 0.30$)
`Partner`	158.73	1	2.14×10^{-36}	0.1501	Moderada ($0.15 \leq V \leq 0.30$)
`MultipleLines`	11.33	2	3.46×10^{-3}	0.0401	Débil ($V < 0.15$)
`PhoneService`	0.92	1	0.3388	0.0114	*No significativo* ($p \geq 0.05$)
`gender`	0.48	1	0.4866	0.0083	*No significativo* ($p \geq 0.05$)

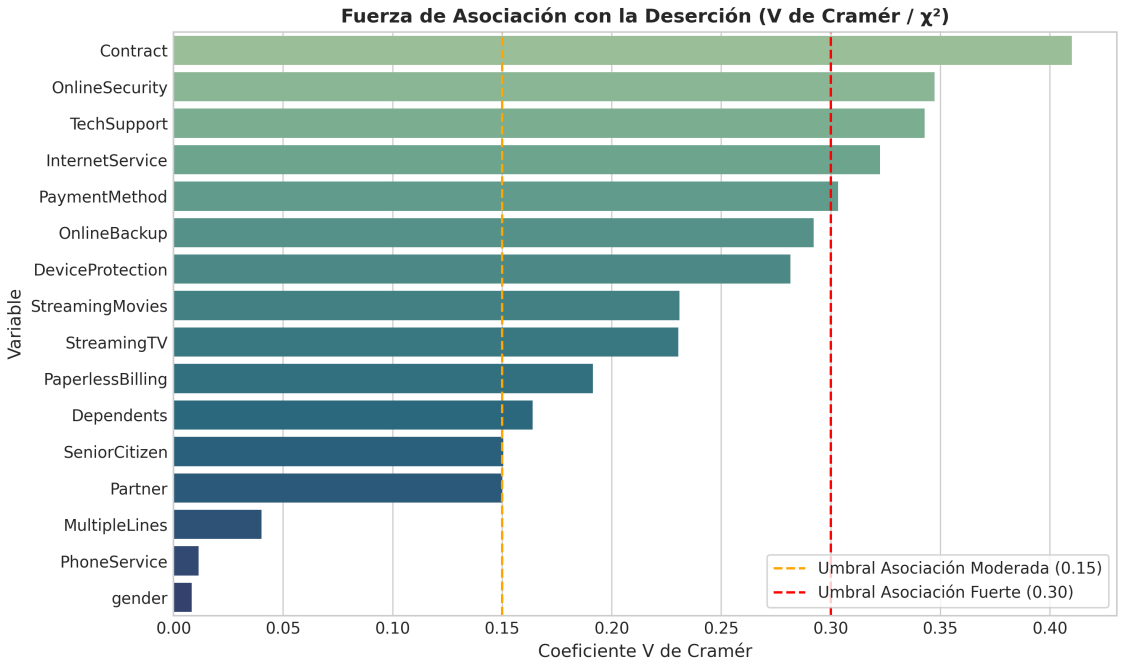


Figura 5: Fuerza de asociación categórica evaluada con el coeficiente V de Cramér.

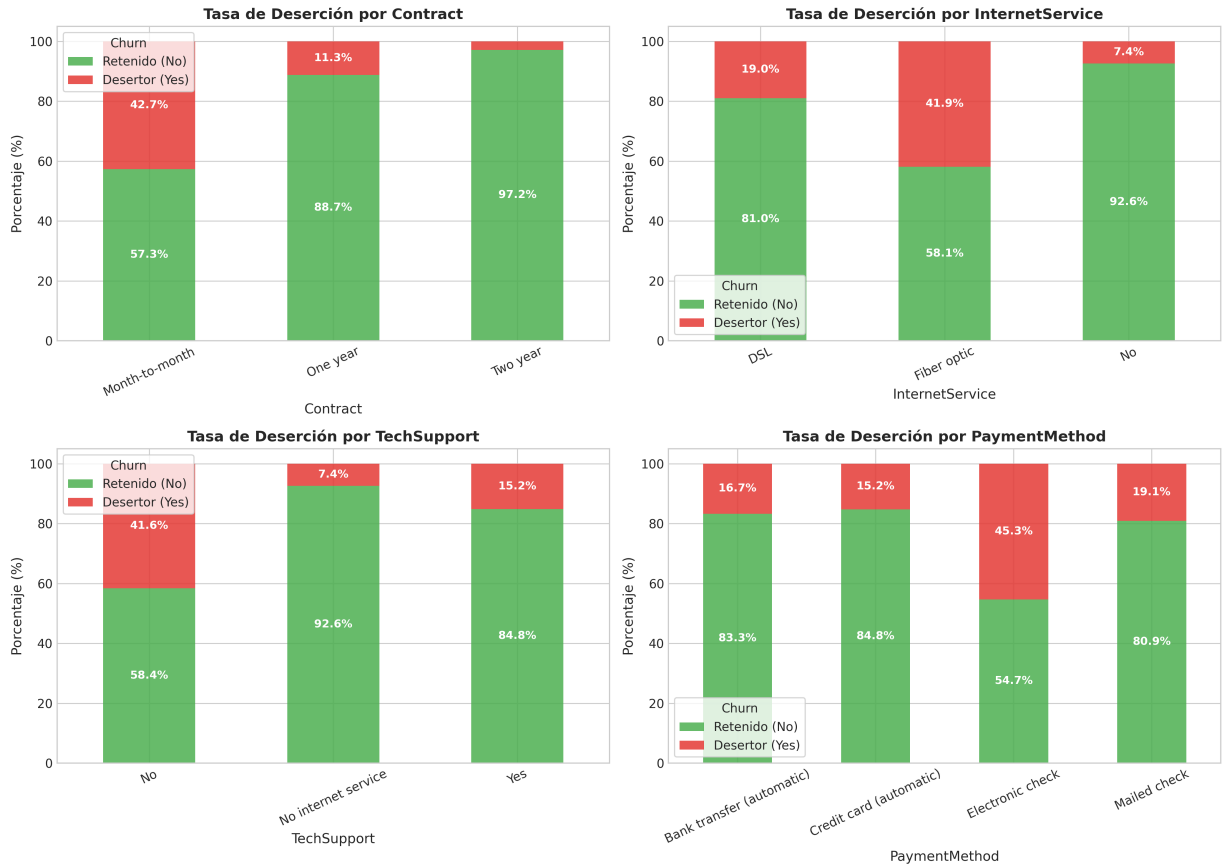


Figura 6: Tasa porcentual de deserción segmentada por factores determinantes de negocio.

3.7. Interpretación y Síntesis Analítica

1. **Impacto Decisivo de la Modalidad Contractual:** `Contract` es la variable con mayor poder explicativo del abandono ($V = 0.4101$, $p \approx 0$). Los suscriptores con contratos mes a mes (*Month-to-month*) presentan una deserción del 42.7 %, mientras que en contratos a un año y dos años la deserción se desploma a 11.3 % y 2.8 % respectivamente (Figura 6).

2. **Efecto Protector de los Servicios de Valor Agregado:** Las características `OnlineSecurity` ($V = 0.3474$) y `TechSupport` ($V = 0.3429$) actúan como amortiguadores de fuga. Los clientes que carecen de soporte técnico exhiben un 41.6 % de deserción, frente a solo un 15.2 % en aquellos con soporte activo.

3. **Tecnología de Internet y Facturación:** Los usuarios con `Fiber optic` muestran una tasa de fuga del 41.9 %, en contraste con el 19.0 % de usuarios con conexión `DSL`. Esto sugiere una insatisfacción latente en la relación costo/beneficio de la fibra. Paralelamente, el método de pago mediante cheque electrónico (*Electronic check*) concentra una deserción del 45.3 %.

4. **Variables No Predictivas e Invariantes:** Se determinó rigurosamente que el género (`gender`, $p = 0.4866$) y la tenencia de telefonía fija básica (`PhoneService`, $p = 0.3388$) son estadísticamente independientes de la deserción. Este hallazgo permitirá suprimir estas columnas o descartarlas en el proceso de selección de características de la Fase 2, reduciendo la dimensionalidad sin pérdida de capacidad explicativa.

4. Conclusiones Metodológicas y Plan de Acción para la Fase 2

1. **Manejo de Calidad de Datos para Fase 2:** Se formalizó que la ausencia de los 11 valores en `TotalCharges` corresponde al mecanismo MAR condicionado por `tenure = 0`. Se realizará una imputación exacta por cero (`TotalCharges = 0.0`), garantizando la preservación completa de la muestra sin introducir distorsiones estadísticas.

2. **Diseño de Ingeniería de Variables (Feature Engineering):** En cumplimiento estricto con los requerimientos de la Fase 2, se derivarán al menos dos variables fundamentadas en el dominio:

   - **Variable Derivada 1 (`ChargeRatio`):** Razón de cobro promedio mensual $\frac{\texttt{TotalCharges}}{\texttt{tenure}+1}$, contrastada frente a `MonthlyCharges` para detectar incrementos tarifarios recientes.
   - **Variable Derivada 2 (`TotalServices`):** Conteo acumulado de servicios contratados (0 a 6) entre seguridad, copias, soporte, póliza de dispositivo y streaming, para medir la adherencia tecnológica.

3. **Estrategia de Partición y Prevención de Fuga de Información (*Data Leakage*):** Se dividirá el conjunto en 70 % Entrenamiento, 15 % Validación y 15 % Prueba mediante muestreo estratificado (`StratifiedShuffleSplit`). Toda transformación, escalado (`StandardScaler` / `RobustScaler`) y codificación (`OneHotEncoder` para nominales y `OrdinalEncoder` para contratos) se ajustará exclusivamente sobre el conjunto de entrenamiento.

4. **Establecimiento del Modelo Base (*Baseline*):** En regresión se construirá una regresión lineal univariable `TotalCharges` $\sim$ `tenure`, y en clasificación un clasificador mayoritario (*DummyClassifier*) y una regresión logística simple para definir el umbral inferior de rendimiento.

Fin del Informe Técnico de la Fase 1