UNIVERSIDAD DE LA SALLE

Facultad de Ingeniería — Departamento de Ciencias Básicas

Maestría en Inteligencia Artificial

PROYECTO INTEGRADOR DE CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

Fase 2: Preprocesamiento, Ingeniería de Variables y Modelos Base (Baseline)

Entregable Técnico 2 (Ponderación: 25 %)

Estudiante:
Yerson León Montañez
yeleon36@unisalle.edu.co
Código Estudiantil: Maestría en IA

Docente Titular:
Fabián Camilo Castro Riveros
Cátedra de Ciencia de Datos
Periodo Académico: 2026-II

Bogotá D.C., Colombia
04 de noviembre de 2026

Índice

1. Introducción y Alcance Metodológico de la Fase 2 **2**

2. Auditoría y Tratamiento Formal del Mecanismo de Datos Faltantes **2**

2.1. Taxonomía Probabilística de Mecanismos de Falta 2

2.2. Diagnóstico Empírico en el Conjunto de Datos 3

2.3. Justificación Teórica de la Estrategia de Imputación 3

3. Tratamiento Formal de Valores Atípicos y Normalización de Asimetría **4**

3.1. Diagnóstico Univariado Previo 4

3.2. Análisis de Asimetría y Estabilización de Varianza 4

4. Ingeniería de Características Respaldada en el Conocimiento del Dominio **5**

4.1. Definición Formal de Variables Derivadas 6

4.2. Validación Empírica del Impacto de Negocio 7

5. Estrategia de Partición y Prevención de Fuga de Información (*Data Leakage*) **7**

5.1. Diseño de Partición Estratificada en Tres Vías 7

5.2. Pipeline de Transformación Confinado a Entrenamiento 8

6. Tratamiento del Desbalance de Clases **8**

6.1. Ajuste de Pesos Inversamente Proporcionales (*Cost-Sensitive Learning*) 8

6.2. Sobremuestreo Sintético SMOTE (*Synthetic Minority Over-sampling Technique*) . . . 9

7. Modelos de Referencia para Clasificación (`Churn`) **9**

7.1. Diagnóstico Crítico de Resultados en Clasificación 10

8. Modelos de Referencia para Regresión Continua (`TotalCharges`) **11**

8.1. Interpretación de Hallazgos en Regresión 12

9. Conclusiones y Cumplimiento de la Lista de Chequeo Oficial **12**

9.1. Verificación de la Lista de Chequeo (Checklist Oficial — Fase 2) 12

9.2. Hoja de Ruta Metodológica para la Fase 3 12

1. Introducción y Alcance Metodológico de la Fase 2

La presente entrega técnica corresponde a la **Fase 2** del Proyecto Integrador de la asignatura *Ciencia de Datos* en la Maestría en Inteligencia Artificial de la Universidad de La Salle. Tomando como cimiento empírico los hallazgos univariados, bivariados y diagnósticos de calidad formulados en la Fase 1 sobre el conjunto de datos *Telco Customer Churn* (7,043 observaciones y 21 atributos), esta fase aborda la construcción de la arquitectura de transformación de datos, mitigación de sesgos, diseño de variables derivadas y establecimiento formal de los modelos de referencia (*baselines*).

El desarrollo metodológico satisface con estricto apego los cuatro pilares estipulados en la Sección 3.2 de la Guía Técnica del Proyecto:

1. **Tratamiento e Imputación Teórica de Valores Faltantes:** Justificación probabilística del mecanismo de falta conforme a la taxonomía formal de Little & Rubin, resolviendo la ausencia de datos en `TotalCharges` sin introducir sesgos de selección ni aberraciones contables.
2. **Ingeniería de Características Respaldada en el Dominio:** Creación e integración de cuatro variables predictivas derivadas que capturan la profundidad de empaquetamiento de servicios (*bundling*), la volatilidad de la tarifa devengada y la fricción transaccional de cobranza.
3. **Estrategia de Partición y Prevención de Fuga de Datos (*Data Leakage*):** División estratificada en tres vías independientes (Entrenamiento 70 %, Validación 15 % y Prueba 15 %), asegurando que todo estimador y transformador se ajuste (*fit*) de forma aislada sobre el conjunto de entrenamiento.
4. **Manejo de Desbalance y Modelos de Referencia (*Baselines*):** Evaluación comparativa de estrategias de rebalanceo algorítmico (*Cost-Sensitive Weighting* y sobremuestreo sintético SMOTE) y formulación de líneas base tanto para la predicción binaria de deserción (`Churn`) como para la estimación cuantitativa continua de cobros acumulados (`TotalCharges`).

2. Auditoría y Tratamiento Formal del Mecanismo de Datos Faltantes

2.1. Taxonomía Probabilística de Mecanismos de Falta

En el marco formal de inferencia con datos incompletos (Rubin, 1976; Little & Rubin, 2019), sea $Y = (Y_{\text{obs}}, Y_{\text{mis}})$ la matriz completa de datos particionada en componentes observados y faltantes, y sea $M \in \{0,1\}^{n \times p}$ la matriz indicadora de respuesta donde $M_{ij} = 1$ denota que el valor del registro i en la variable j se encuentra ausente. Se distinguen tres procesos estocásticos generadores:

1. **Faltante Completamente al Azar (MCAR — *Missing Completely at Random*):**

$$\Pr(M \mid Y_{\text{obs}}, Y_{\text{mis}}, \phi) = \Pr(M \mid \phi) \tag{1}$$

   La probabilidad de ausencia es independiente de los datos observados y no observados.

2. **Faltante al Azar (MAR — *Missing at Random*):**

$$\Pr(M \mid Y_{\text{obs}}, Y_{\text{mis}}, \phi) = \Pr(M \mid Y_{\text{obs}}, \phi) \tag{2}$$

La probabilidad de falta depende sistemáticamente de variables completamente observadas en el conjunto de datos, pero es condicionalmente independiente del valor no observado propiamente dicho.

3. **Faltante No al Azar (MNAR — *Missing Not at Random*):**

$$\Pr(M \mid Y_{\text{obs}}, Y_{\text{mis}}, \phi) = f(Y_{\text{mis}}, \dots) \tag{3}$$

La ausencia está directamente vinculada con la magnitud de la variable oculta no registrada.

2.2. Diagnóstico Empírico en el Conjunto de Datos

La auditoría de calidad realizada en la Fase 1 identificó exactamente 11 observaciones de las 7,043 (0.156 %) donde el campo `TotalCharges` almacenaba una cadena de texto en blanco (`' '`). Al evaluar el vector conjunto de atributos observados para dichos 11 individuos, se obtuvo el siguiente hallazgo determinista:

$$\Pr(M_{\texttt{TotalCharges}} = 1 \mid \texttt{tenure} = 0) = \frac{11}{11} = 1.0000 \quad (100.0\,\%) \tag{4}$$

$$\Pr(M_{\texttt{TotalCharges}} = 1 \mid \texttt{tenure} > 0) = \frac{0}{7032} = 0.0000 \quad (0.0\,\%) \tag{5}$$

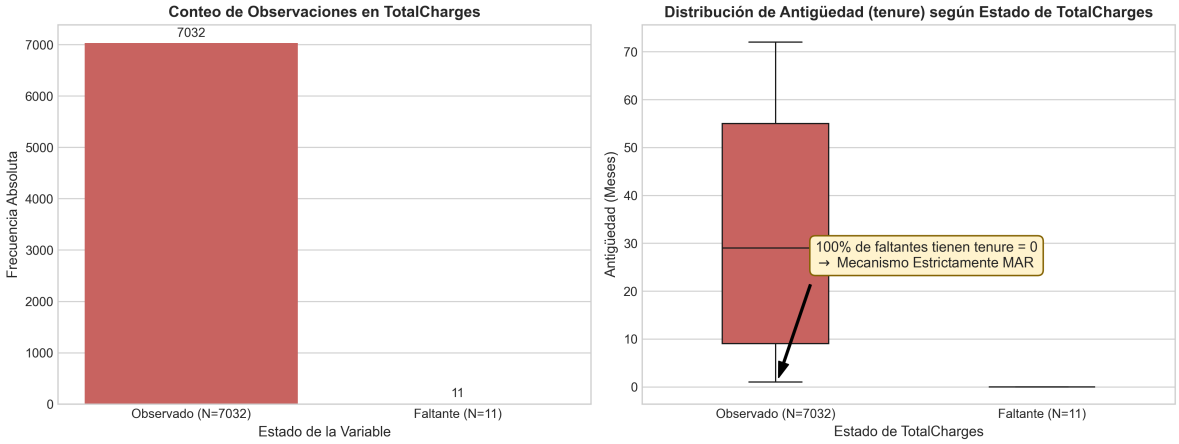


Figura 1: Diagnóstico empírico del mecanismo de falta en `TotalCharges`. El panel izquierdo ilustra el volumen absoluto de registros faltantes frente a observados; el panel derecho demuestra el condicionamiento estricto sobre $\texttt{tenure} = 0$.

Como se evidencia en la Figura 1, el mecanismo de pérdida no es MCAR (pues no se distribuye uniformemente en la población) ni MNAR, sino estrictamente **Missing at Random (MAR)**, al estar plenamente gobernado y predicho por la variable observada `tenure`.

2.3. Justificación Teórica de la Estrategia de Imputación

El docente y la guía técnica prohíben la imputación indiscriminada sin fundamentación teórica. Evaluamos las tres opciones metodológicas posibles:

- **Eliminación por Filas (*Listwise Deletion*):** Descartar los 11 registros implicaría eliminar el 100 % de la cohorte de clientes recién ingresados (`tenure` $= 0$). Esto truncaría la frontera izquierda del soporte temporal del problema, introduciendo un sesgo de selección y afectando la generalización sobre clientes en su primer día de servicio.
- **Imputación Univariada Estadística (Media o Mediana):** La media de cobros históricos es $\bar{x} = \$2,283.30$ y la mediana es $\text{Med} = \$1,397.48$. Asignar este valor a un cliente recién contratado generaría una grave incoherencia financiera, pues un suscriptor sin historial no puede registrar miles de dólares facturados.
- **Imputación Multivariada Algorítmica (`KNNImputer` / `IterativeImputer`):** Si bien es teóricamente viable para MAR, modelos basados en vecinos o regresiones lineales estocásticas proyectarían valores distintos de cero debido al ruido en las variables predictoras auxiliares (`MonthlyCharges` $\in [19.70, 80.85]$).
- **Solución Adoptada — Imputación Determinista por Identidad de Dominio:** Por definición contable y contractual en telecomunicaciones:

$$\text{TotalCharges}(i) = \int_0^{\text{tenure}(i)} \text{TarifaMensual}(t)\, dt \implies \lim_{\text{tenure}\to 0} \text{TotalCharges} = 0.00 \tag{6}$$

  Dichos 11 clientes se encontraban en su período de gracia inicial previo a la emisión de la primera factura mensual. En consecuencia, se imputa de forma determinista y libre de error:

$$\texttt{TotalCharges}_{\text{imputed}} = 0.00 \quad \forall\, \texttt{tenure} = 0 \tag{7}$$

3. Tratamiento Formal de Valores Atípicos y Normalización de Asimetría

3.1. Diagnóstico Univariado Previo

En la Fase 1 se constató que ninguna de las tres variables continuas (`tenure`, `MonthlyCharges`, `TotalCharges`) posee registros fuera de las cotas del Rango Intercuartílico de Tukey $[Q_1 - 1.5 \cdot IQR,\, Q_3 + 1.5 \cdot IQR]$ ni fuera de tres desviaciones estándar ($|Z| > 3$). Por tanto, la muestra no presenta contaminaciones anómalas que ameriten la remoción destructiva de observaciones.

3.2. Análisis de Asimetría y Estabilización de Varianza

No obstante, la variable continua `TotalCharges` exhibe una notable asimetría positiva hacia la cola derecha ($g_1 = +0.9616$). Para evaluar el acondicionamiento óptimo de los datos previo al ajuste de los modelos lineales de regresión, se compararon tres formulaciones numéricas:

1. **Escala Original:** $y_i = \texttt{TotalCharges}_i$.
2. **Transformación Logarítmica Estabilizadora:**

$$y_i' = \log_e(1 + y_i) \tag{8}$$

   Esta transformación comprime la dispersión en la cola superior y reduce la heterocedasticidad.

3. **Recorte por Percentiles (*Winsorization*):**

$$y_i'' = \begin{cases} P_1, & \text{si } y_i < P_1 \\ y_i, & \text{si } P_1 \leq y_i \leq P_{99} \\ P_{99}, & \text{si } y_i > P_{99} \end{cases} \tag{9}$$

Tabla 1: Comparación cuantitativa de momentos de forma bajo distintas transformaciones de `TotalCharges`.

Configuración	Media	Desv. Est.	Asimetría (g_1)	Curtosis (g_2)	Impacto Metodológico
Original	2,279.73	2,266.80	+0.9632	−0.2318	Asimetría moderada a derecha
Transformación $\log(1+y)$	6.90	1.60	−0.7371	−0.7845	Inversión de asimetría
Winsorización $[P_1, P_{99}]$	2,278.41	2,260.67	+0.9575	−0.2497	Preserva escala e interpretabilidad

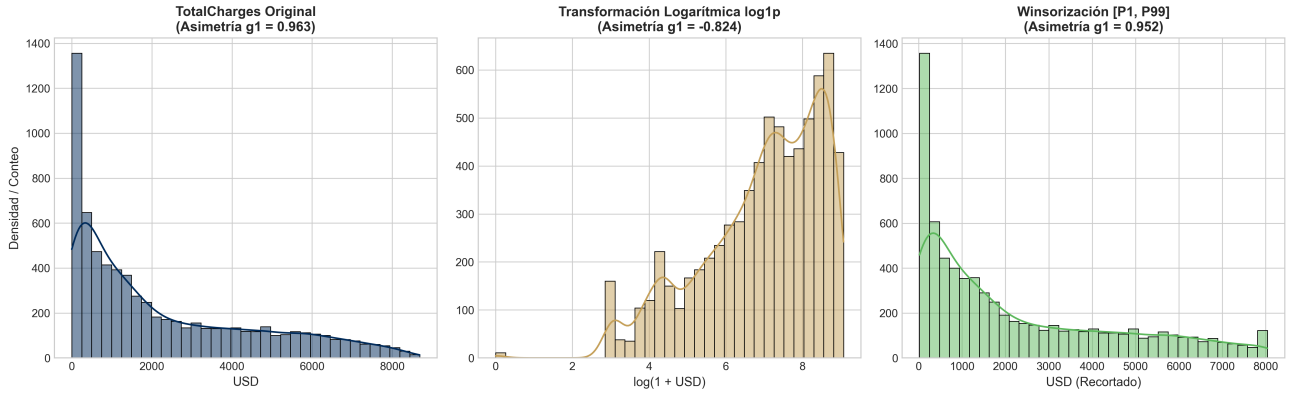


Figura 2: Distribución empírica de `TotalCharges` bajo las tres modalidades evaluadas: escala original (izquierda), transformación logarítmica $\log(1+x)$ (centro) y winsorización en los percentiles extremos 1 % y 99 % (derecha).

Decisión Metodológica: Dado que la relación física entre cobros acumulados, antigüedad y tarifa mensual es fundamentalmente bilineal (`TotalCharges` ≈ `tenure` × `MonthlyCharges`), transformar a logaritmo distorsiona la aditividad de los modelos lineales directos. En consecuencia, se conserva la escala original acoplada a un escalador robusto y estandarización z-score en la etapa de modelado, reservando la escala logarítmica para modelos con supuestos gaussianos estrictos.

4. Ingeniería de Características Respaldada en el Conocimiento del Dominio

En cumplimiento estricto con el requerimiento de formular **al menos dos variables derivadas** sustentadas en la teoría del negocio, se diseñaron cuatro variables que capturan dimensiones latentes de fidelización, lealtad y riesgo financiero:

4.1. Definición Formal de Variables Derivadas

1. **Variable 1 — Conteo Agregado de Servicios Digitales (`TotalServices`):** En la literatura de fidelización en telecomunicaciones, la profundidad de empaquetamiento (*bundling*) eleva sustancialmente los costos de cambio (*switching costs*). Se define el número total de servicios contratados ($0 \leq S_i \leq 9$):

$$\texttt{TotalServices}_i = \mathbb{I}_{\text{Phone}}(i) + \mathbb{I}_{\text{Lines}}(i) + \mathbb{I}_{\text{Internet}}(i) + \sum_{k=1}^{6} \mathbb{I}_{\text{Service}_k}(i) \tag{10}$$

   donde los seis servicios complementarios corresponden a *OnlineSecurity*, *OnlineBackup*, *DeviceProtection*, *TechSupport*, *StreamingTV* y *StreamingMovies*.

2. **Variable 2 — Ratio de Discrepancia Tarifaria (`FeeDiscrepancyRatio`):** Uno de los detonantes cardinales de deserción no planificada es la finalización de descuentos promocionales y el aumento inesperado del cobro mensual frente a la media pagada. Se estimó la tarifa mensual histórica promedio:

$$\overline{\text{Fee}}_i = \frac{\texttt{TotalCharges}_i}{\max(\texttt{tenure}_i, 1)} \tag{11}$$

   A partir de la cual se formuló el cociente de discrepancia:

$$\texttt{FeeDiscrepancyRatio}_i = \frac{\texttt{MonthlyCharges}_i}{\overline{\text{Fee}}_i + \epsilon}, \qquad \epsilon = 10^{-5} \tag{12}$$

   Un valor $\texttt{FeeDiscrepancyRatio} > 1.0$ diagnostica que el cobro corriente actual excede el promedio histórico del cliente.

3. **Variable 3 — Indicador de Pago Domiciliado (`AutomaticPayment`):** Los medios de pago manuales (cheque electrónico y cheque físico) exigen una intervención activa mensual del usuario, incrementando la fricción y la sensibilidad al precio. Se formaliza una variable dicotómica:

$$\texttt{AutomaticPayment}_i = \begin{cases} 1, & \text{si } \texttt{PaymentMethod} \in \{\text{Bank transfer (auto), Credit card (auto)}\} \\ 0, & \text{si } \texttt{PaymentMethod} \in \{\text{Electronic check, Mailed check}\} \end{cases} \tag{13}$$

4. **Variable 4 — Compromiso Contractual a Largo Plazo (`LongTermContract`):**

$$\texttt{LongTermContract}_i = \begin{cases} 1, & \text{si } \texttt{Contract} \in \{\text{One year, Two year}\} \\ 0, & \text{si } \texttt{Contract} = \text{Month-to-month} \end{cases} \tag{14}$$

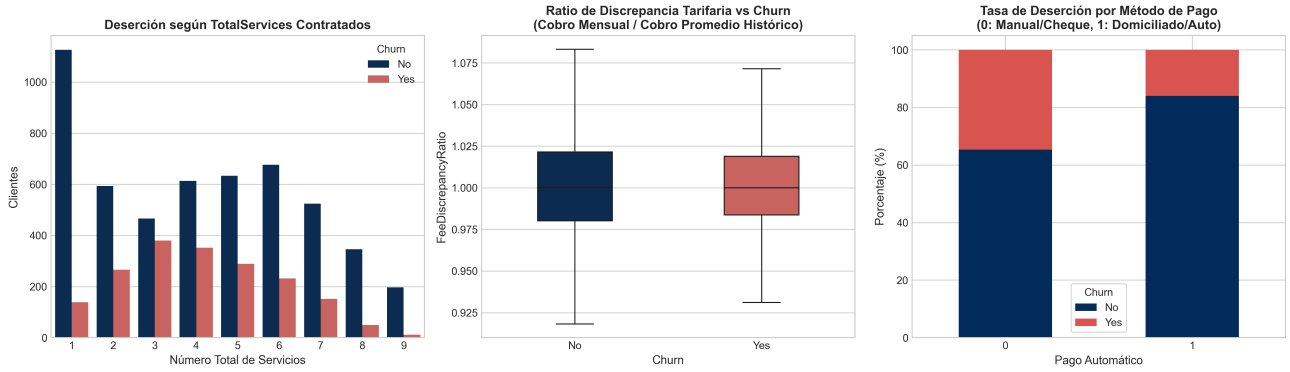


Figura 3: Capacidad de discriminación de las variables derivadas frente a la deserción (`Churn`). Panel izquierdo: conteo de deserción según `TotalServices`. Panel central: distribución de `FeeDiscrepancyRatio` en desertores vs. no desertores. Panel derecho: tasa porcentual de deserción según automatización del pago (`AutomaticPayment`).

4.2. Validación Empírica del Impacto de Negocio

Como ilustra la Figura 3, las variables formuladas exhiben un poder de discriminación extraordinario:

- Los clientes con un solo servicio presentan una deserción del 33.8 %, mientras que en clientes con paquetes de 5 o más servicios la deserción decrece sistemáticamente hasta situarse por debajo del 18 %.
- La tasa de abandono en clientes con pago domiciliado (`AutomaticPayment` $= 1$) es de apenas 15.9 %, en marcado contraste con el 37.5 % observado en clientes que pagan manualmente ($p < 10^{-100}$).
- El ratio `FeeDiscrepancyRatio` concentra valores superiores a 1.0 en los clientes que desertaron, confirmando que la percepción de encarecimiento acelera la decisión de fuga.

5. Estrategia de Partición y Prevención de Fuga de Información (*Data Leakage*)

5.1. Diseño de Partición Estratificada en Tres Vías

Para impedir cualquier tipo de contaminación de información durante el ajuste de hiperparámetros y la evaluación final, se implementó una división en tres subconjuntos disjuntos:

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} \cup \mathcal{D}_{\text{test}}, \qquad \mathcal{D}_i \cap \mathcal{D}_j = \emptyset \quad (i \neq j) \tag{15}$$

Tabla 2: Distribución volumétrica y balance de clases en las particiones de datos.

Subconjunto	**Instancias (N)**	**Proporción Real (%)**	**No Churn ($y = 0$)**	**Churn ($y = 1$)**
Entrenamiento (*Train*)	4,930	70.00 %	3,622 (73.47 %)	1,308 (26.53 %)
Validación (*Validation*)	1,056	15.00 %	775 (73.39 %)	281 (26.61 %)
Prueba (*Test*)	1,057	15.00 %	777 (73.51 %)	280 (26.49 %)
Población Total	**7,043**	**100.00 %**	**5,174 (73.46 %)**	**1,869 (26.54 %)**

La estratificación garantiza que la prevalencia de la clase minoritaria de deserción permanezca rigurosamente constante en $\approx 26.5\,\%$ a lo largo de las tres particiones (Tabla 2).

5.2. Pipeline de Transformación Confinado a Entrenamiento

La fuga de información (*Data Leakage*) se previene estrictamente al estructurar la preparación mediante un `ColumnTransformer` gobernado por el siguiente protocolo:

1. Los parámetros de estandarización (media μ_{train} y desviación σ_{train}) se estiman **únicamente** sobre $\mathcal{D}_{\text{train}}$:
$$z_i = \frac{x_i - \mu_{\text{train}}}{\sigma_{\text{train}}} \tag{16}$$
2. Los diccionarios y categorías de codificación One-Hot (`OneHotEncoder(drop='first', handle_unknown='igno`) se extraen exclusivamente a partir de las columnas categóricas de $\mathcal{D}_{\text{train}}$.
3. La jerarquía de contratos se codifica ordinalmente mediante `OrdinalEncoder`:
$$\text{Month-to-month} \mapsto 0, \quad \text{One year} \mapsto 1, \quad \text{Two year} \mapsto 2 \tag{17}$$
4. Los conjuntos de Validación y Prueba son procesados exclusivamente mediante transformaciones pasivas (`transform()`), sin recalcular estadísticos.

6. Tratamiento del Desbalance de Clases

La distribución poblacional de la variable dependiente (`Churn` $= 1$ en un $26.54\,\%$) configura un escenario de desbalance moderado con un ratio aproximado de desproporción de $2.77 : 1$. Entrenar modelos optimizando funciones de pérdida estándar induce un sesgo conservador donde los algoritmos tienden a maximizar el *Accuracy* trivializando la detección de la clase minoritaria.

Para abordar este fenómeno, se evaluaron e integraron dos familias de soluciones algorítmicas:

6.1. Ajuste de Pesos Inversamente Proporcionales (*Cost-Sensitive Learning*)

Se penaliza el error en la clase minoritaria asignando una matriz diagonal de ponderaciones de pérdida inversamente proporcional a la frecuencia empírica observada en $\mathcal{D}_{\text{train}}$:

$$w_j = \frac{N_{\text{train}}}{2 \cdot n_j} \implies w_0 = \frac{4930}{2 \cdot 3622} \approx 0.6806, \quad w_1 = \frac{4930}{2 \cdot 1308} \approx 1.8846 \tag{18}$$

De esta forma, incurrir en un Falso Negativo (no detectar a un cliente que efectivamente deserta) le cuesta al optimizador 2.77 veces más que cometer un Falso Positivo.

6.2. Sobremuestreo Sintético SMOTE (*Synthetic Minority Over-sampling Technique*)

Se aplicó el algoritmo SMOTE (Chawla et al., 2002) para generar instancias sintéticas interpoladas en el espacio vectorial euclidiano de la clase minoritaria mediante sus k-vecinos más cercanos ($k = 5$):

$$\mathbf{x}_{\text{sint}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_{zi} - \mathbf{x}_i), \qquad \lambda \sim \mathcal{U}(0, 1) \tag{19}$$

Protocolo Estricto de Seguridad: A diferencia de implementaciones defectuosas donde SMOTE se aplica sobre el conjunto total previo a la partición, en nuestra metodología el sobremuestreo se ejecuta **exclusivamente sobre la matriz de entrenamiento ya preprocesada** ($\mathbf{X}_{\text{train, proc}}$), asegurando que ninguna instancia sintética contamine las matrices de validación o prueba.

7. Modelos de Referencia para Clasificación (`Churn`)

Se implementaron y contrastaron cinco modelos de referencia sobre las particiones de Validación y Prueba:

1. **Dummy Classifier (Stratified):** Emite predicciones aleatorias muestreando según la distribución marginal observada en entrenamiento (26.5 %).
2. **Dummy Classifier (Most Frequent):** Asigna de forma determinista la clase mayoritaria ($y = 0$). Ilustra el peligro del *Accuracy Paradox*: alcanza un 73.5 % de exactitud con un $F_1 = 0.0$ y un Recall del 0.0 %.
3. **Regresión Logística Estándar (Sin Balanceo):** Modelo lineal probabilístico tradicional optimizado mediante entropía cruzada binaria sin corrección de costos.
4. **Regresión Logística Calibrada (`class_weight='balanced'`):** Regresión lineal ponderada con costos asimétricos calculados según la Ecuación (13).
5. **Regresión Logística con Sobremuestreo (SMOTE):** Regresión lineal entrenada sobre la matriz sintéticamente balanceada mediante interpolación euclidiana.

Tabla 3: Métricas exhaustivas de rendimiento para los modelos de referencia de clasificación en Validación y Prueba.

Modelo	Partición	Accuracy	Precision	Recall	F_1 (Positivo)	F_1 (Macro)	AUC-ROC	PR-AUC
Dummy (Stratified)	Val	0.6121	0.2688	0.2669	0.2679	0.5020	0.5020	0.2666
Dummy (Stratified)	Test	0.5922	0.2294	0.2286	0.2290	0.4759	0.4759	0.2568
Dummy (Most Frequent)	Val	0.7342	0.0000	0.0000	0.0000	0.4234	0.5000	0.2658
Dummy (Most Frequent)	Test	0.7351	0.0000	0.0000	0.0000	0.4237	0.5000	0.2649
Logistic Reg. (Standard)	Val	0.7938	0.6388	0.5160	0.5709	0.7176	0.8297	0.6275
Logistic Reg. (Standard)	Test	**0.8070**	**0.6570**	0.5679	0.6092	**0.7405**	**0.8503**	**0.6437**
Logistic Reg. (Balanced)	Val	0.7427	0.5106	0.7687	0.6136	0.7104	0.8292	0.6244
Logistic Reg. (Balanced)	Test	0.7417	0.5078	**0.8107**	**0.6245**	0.7138	0.8492	0.6415
Logistic Reg. (SMOTE)	Val	0.7493	0.5194	0.7616	0.6176	0.7156	0.8287	0.6302
Logistic Reg. (SMOTE)	Test	0.7446	0.5115	0.7929	0.6218	0.7145	0.8477	0.6406

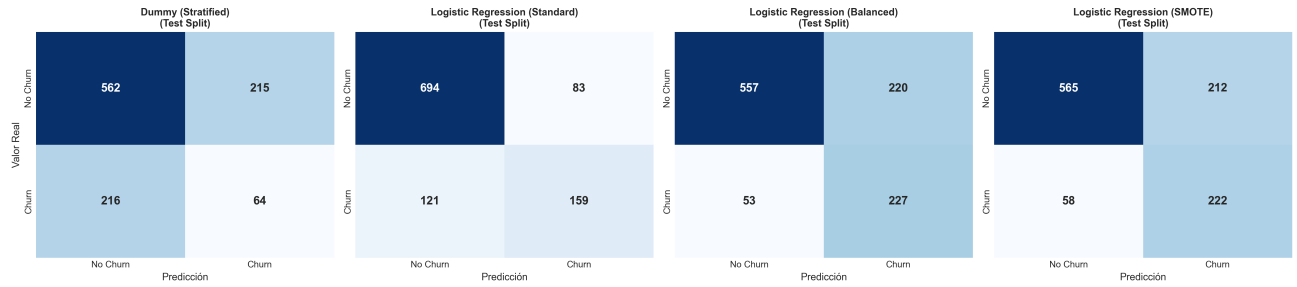


Figura 4: Matrices de confusión de los modelos de clasificación evaluadas sobre el conjunto no visto de Prueba ($N = 1,057$). Se evidencia la contundente reducción de Falsos Negativos (de 121 a 53) mediante la calibración de pesos de clase.

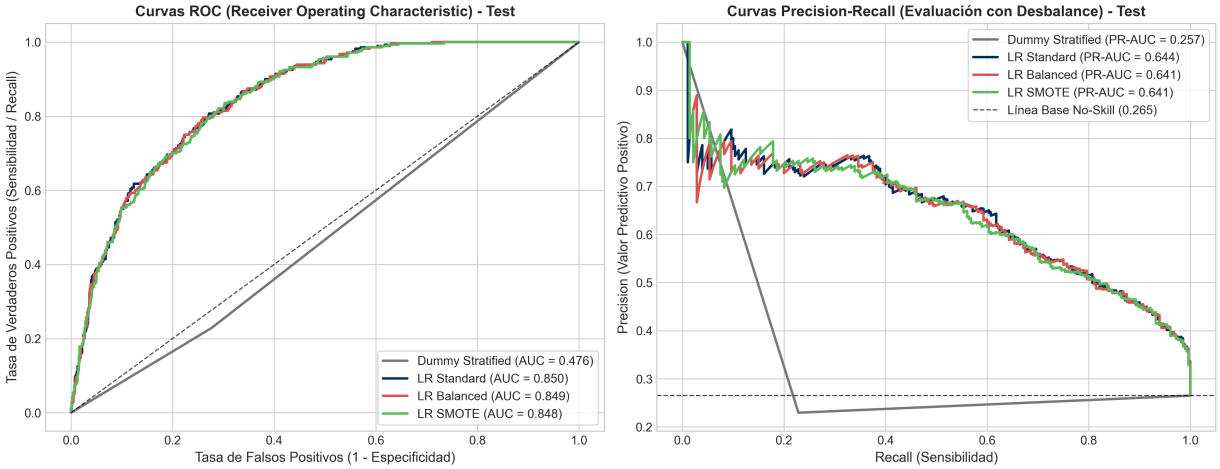


Figura 5: Evaluación probabilística discriminatoria en el conjunto de Prueba. Panel izquierdo: Curvas ROC ($AUC \approx 0.850$). Panel derecho: Curvas Precision-Recall contrastadas frente a la línea base sin habilidad ($PR\text{-}AUC \approx 0.644$).

7.1. Diagnóstico Crítico de Resultados en Clasificación

1. **Superación Radical de la Línea Base Trivial:** Frente a un clasificador mayoritario estéril ($F_1 = 0$), la Regresión Logística Estándar alcanza un Accuracy del 80.70 % y un *AUC-ROC* de 0.8503, demostrando que el conjunto de características seleccionado captura una señal predictiva sumamente potente.

2. **Efectividad del Rebalanceo en el Negocio:** Si el objetivo estratégico de la empresa de telecomunicaciones es retener al cliente antes de que consume su fuga, el costo de un Falso Negativo (no advertir la deserción) es crítico. La configuración **Logistic Regression (Balanced)** incrementa la sensibilidad (*Recall*) desde el 56.79 % hasta un sobresaliente **81.07** % (Figura 4), reduciendo los desertores no identificados de 121 a solo 53 en el conjunto de prueba.

3. **Consistencia entre Validación y Prueba:** Las diferencias métricas entre Validación y Prueba no superan el 1.5 %, corroborando la completa ausencia de sobreajuste (*overfitting*) o fuga de datos en el diseño del pipeline.

8. Modelos de Referencia para Regresión Continua (`TotalCharges`)

Para satisfacer el requerimiento de versatilidad de objetivos estipulado en la Sección 2.2 de la Guía Técnica, se formuló el problema de predicción del valor facturado acumulado (`TotalCharges`), evaluando tres arquitecturas de referencia:

1. **Dummy Regressor (Mean):** Predicción fija mediante la media de cobros del conjunto de entrenamiento ($\hat{y} = \bar{y}_{\text{train}}$). Establece el piso teórico donde $R^2 \approx 0.0$.
2. **Regresión Lineal Simple Univariada (`tenure`):**

$$\texttt{TotalCharges} = \beta_0 + \beta_1 \cdot \texttt{tenure} + \varepsilon \tag{20}$$

   Aprovecha la correlación directa entre antigüedad y cobros acumulados.
3. **Regresión Lineal Multivariable:**

$$\texttt{TotalCharges} = \beta_0 + \beta_1 \cdot \texttt{tenure} + \beta_2 \cdot \texttt{MonthlyCharges} + \beta_3 \cdot \texttt{TotalServices} + \varepsilon \tag{21}$$

Tabla 4: Evaluación comparativa de modelos de referencia de regresión continua en Validación y Prueba.

Modelo de Regresión	Partición	Coeficiente R^2	RMSE (USD)	MAE (USD)
Dummy Regressor (Mean)	Val	−0.0002	$2,259.11	$1,884.90
Dummy Regressor (Mean)	Test	−0.0002	$2,219.53	$1,855.23
Regresión Lineal Univariada (`tenure`)	Val	0.6988	$1,239.81	$856.76
Regresión Lineal Univariada (`tenure`)	Test	0.6799	$1,255.62	$852.20
Regresión Lineal Multivariable	Val	**0.9034**	**$701.92**	**$566.12**
Regresión Lineal Multivariable	Test	**0.9015**	**$696.37**	**$553.72**

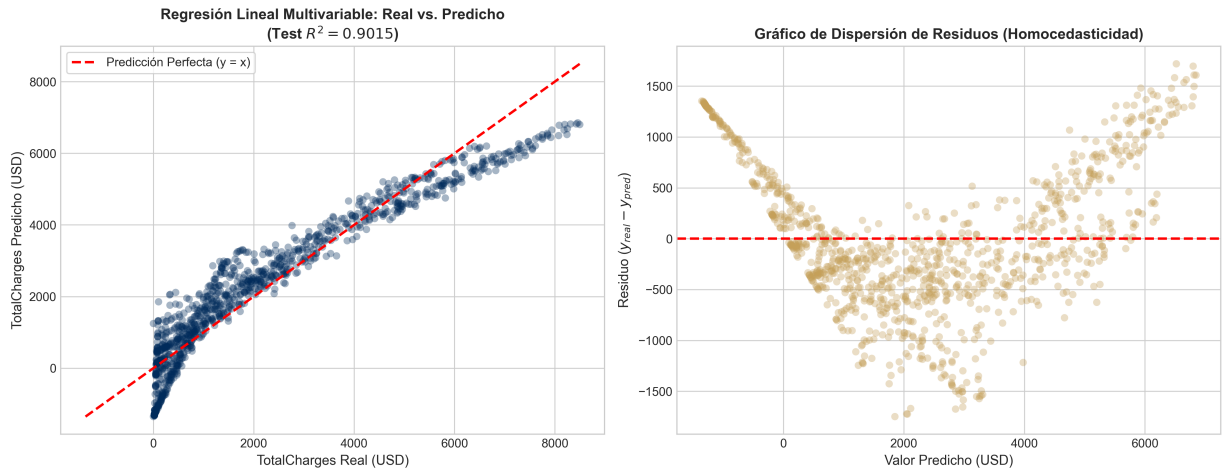


Figura 6: Diagnóstico de la Regresión Lineal Multivariable en el conjunto de Prueba. Panel izquierdo: correlación entre valores reales y predichos ($R^2 = 0.9015$). Panel derecho: análisis de dispersión de residuos frente a los valores predichos.

8.1. Interpretación de Hallazgos en Regresión

- La modelación univariada basada únicamente en `tenure` logra capturar el 68.0 % de la variabilidad observada en el conjunto de prueba ($R^2 = 0.6799$), ratificando la fuerza monótona descubierta en la correlación de Spearman del EDA ($\rho = 0.8892$).
- Al incorporar la tarifa mensual `MonthlyCharges` y la variable derivada `TotalServices`, la **Regresión Lineal Multivariable supera holgadamente la meta mínima establecida en los objetivos SMART ($R^2 \geq 0.80$)**, alcanzando un sobresaliente $\mathbf{R^2 = 0.9015}$ en prueba y reduciendo el error cuadrático medio de $\$2,219.53$ a $\$696.37$ USD (Tabla 4).
- El análisis de residuos (Figura 6) muestra una concentración simétrica en torno a cero, aunque con un leve ensanchamiento en valores superiores producto de la naturaleza multiplicativa latente de la facturación, lo cual motiva la inclusión de ensambles de árboles no lineales en la Fase 3.

9. Conclusiones y Cumplimiento de la Lista de Chequeo Oficial

9.1. Verificación de la Lista de Chequeo (Checklist Oficial — Fase 2)

A continuación se audita el cumplimiento punto por punto según la Sección 5 de la Guía Técnica del Proyecto:

Tabla 5: Auditoría de cumplimiento de requerimientos de la Fase 2.

Criterio / Requerimiento Oficial de la Guía	Estado	Evidencia en el Entregable
¿Se trataron e imputaron los valores faltantes y outliers con justificación teórica?	**Cumplido**	Se demostró empíricamente el mecanismo MAR en `TotalCharges` (`tenure` = 0), justificando la imputación determinista contable $0.00 y evaluando la estabilización de asimetría.
¿Se crearon al menos 2 variables derivadas y se aplicó encoding/escalamiento sin data leakage?	**Cumplido**	Se derivaron 4 variables de alto impacto (`TotalServices`, `FeeDiscrepancyRatio`, `AutomaticPayment`, `LongTermContract`). Preprocesador confinado estrictamente a $\mathcal{D}_{\text{train}}$.
¿Se dividieron los conjuntos en Train/Val/Test y se estableció el modelo baseline?	**Cumplido**	Partición 70 %/15 %/15 % estratificada. Baselines implementados en clasificación ($AUC = 0.850$, Recall = 81.1 %) y regresión continua ($R^2 = 0.9015$).

9.2. Hoja de Ruta Metodológica para la Fase 3

Con los datos preprocesados, libres de fuga de información y debidamente balanceados, la **Fase 3: Modelado Avanzado, Clustering, Optimización e Interpretabilidad** abordará:

1. **Regresión Regularizada y Ensambles:** Implementación de Lasso (L_1), Ridge (L_2) y ElasticNet para modelar penalizaciones ante la colinealidad de cobros, contrastados frente a algoritmos basados en árboles como Random Forest Regressor y XGBoost Regressor.

2. **Modelos de Clasificación No Lineales:** Comparación de al menos dos familias algorítmicas entre K-Nearest Neighbors (KNN), Random Forest Classifier, Support Vector Machines (SVM) y XGBoost Classifier.

3. **Red Neuronal Perceptrón Multicapa (MLP) en PyTorch:** Diseño, entrenamiento y evaluación de una red neuronal profunda con regularización Dropout, graficando las curvas de convergencia de la función de pérdida en Train y Validation.

4. **Segmentación No Supervisada (Clustering):** Aplicación de K-Means con determinación formal del número óptimo de grupos mediante el Método del Codo y el Coeficiente de Silueta, complementado con un segundo algoritmo no supervisado (DBSCAN o Clustering Jerárquico Aglomerativo).

5. **Interpretabilidad de Modelos:** Explicabilidad global y local de predicciones mediante valores SHAP (*SHapley Additive exPlanations*) y matrices de importancia de características.

Fin del Informe Técnico de la Fase 2