UNIVERSIDAD DE LA SALLE

Facultad de Ingeniería — Departamento de Ciencias Básicas

Maestría en Inteligencia Artificial

PROYECTO INTEGRADOR DE CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

Fase 3: Modelado Avanzado, Clustering, Optimización e Interpretabilidad

Entregable Técnico 3 (Ponderación: 25 %)

Estudiante:
Yerson León Montañez
yeleon36@unisalle.edu.co
Código Estudiantil: Maestría en IA

Docente Titular:
Fabián Camilo Castro Riveros
Cátedra de Ciencia de Datos
Periodo Académico: 2026-II

Bogotá D.C., Colombia
04 de noviembre de 2026

Índice

1. Introducción y Alcance Metodológico de la Fase 3 **2**

2. Modelos de Regresión Continua Regularizada y Ensambles **2**

2.1. Formulación Matemática de Modelos Penalizados 2

2.2. Algoritmos de Ensamble No Lineales 3

2.3. Diagnóstico de Resultados en Regresión 4

3. Modelos de Clasificación Supervisada y Perceptrón Multicapa (PyTorch MLP) **4**

3.1. Arquitectura y Calibración de Algoritmos Supervisados 4

3.2. Análisis Crítico de la Clasificación 6

4. Modelos de Aprendizaje No Supervisado: Clustering y Segmentación **6**

4.1. Selección del Espacio de Características y Preprocesamiento 6

4.2. Determinación del Número Óptimo de Clústeres (K) 6

4.3. Comparación con Clustering Jerárquico Aglomerativo 7

4.4. Perfilamiento Profiláctico y Valor Práctico para el Negocio 7

4.4.1. Implicaciones Estratégicas para la Organización 8

5. Interpretabilidad de Modelos y Explicabilidad con Valores SHAP **8**

5.1. Marco Axiomático de Shapley 8

5.2. Jerarquía de Importancia y Dinámica de Fuga 9

6. Conclusiones Metodológicas y Lista de Chequeo Oficial **10**

6.1. Auditoría de la Lista de Chequeo (Fase 3) 10

6.2. Hoja de Ruta Metodológica para la Fase 4 (Puesta en Producción) 10

1. Introducción y Alcance Metodológico de la Fase 3

La presente entrega técnica corresponde a la **Fase 3** del Proyecto Integrador en la Maestría en Inteligencia Artificial de la Universidad de La Salle. Partiendo de la base empírica establecida en el Análisis Exploratorio de Datos (Fase 1) y de la tubería de preprocesamiento, partición estratificada sin fuga de información (*data leakage*) e ingeniería de características formulada en la Fase 2, esta etapa implementa el modelado algorítmico avanzado para abordar de forma integral la predicción supervisada y la segmentación no supervisada del conjunto de datos de telecomunicaciones.

El desarrollo metodológico satisface con estricto rigor los requerimientos de la Sección 3.3 y la lista de chequeo oficial:

1. **Modelos de Regresión Continua Regularizada y Ensambles:** Formulación de modelos lineales penalizados (Ridge L_2 y Lasso L_1) con optimización de hiperparámetros mediante Validación Cruzada de 5 pliegues (*5-Fold Cross-Validation*), complementados con algoritmos de ensamble basados en árboles (Random Forest Regressor y XGBoost Regressor) para capturar las interacciones multiplicativas inherentes a la facturación acumulada (`TotalCharges`).
2. **Modelos de Clasificación Supervisada y Red Neuronal en PyTorch:** Comparación de clasificadores no lineales avanzados (Random Forest y XGBoost Classifier) calibrados contra el desbalance poblacional, complementados con el diseño, entrenamiento y evaluación de un Perceptrón Multicapa (MLP) en PyTorch con normalización por capas (*LayerNorm*), regularización estocástica (*Dropout*) y seguimiento de la función de pérdida por época en los conjuntos de entrenamiento y validación.
3. **Aprendizaje No Supervisado (Clustering y Segmentación):** Determinación explícita del número óptimo de agrupaciones (K) mediante la evaluación convergente del Método del Codo (Inercia WCSS) y el Coeficiente de Silueta en K-Means, contrastado frente a un segundo algoritmo no supervisado (Clustering Jerárquico Aglomerativo con enlace de Ward), finalizando con un perfilamiento profiláctico de negocio de los segmentos descubiertos.
4. **Interpretabilidad de Modelos (XAI):** Explicabilidad global y local del mejor modelo de clasificación predictiva mediante el cálculo exacto de valores SHAP (*SHapley Additive exPlanations*), identificando las variables rectoras de la retención y el abandono.

2. Modelos de Regresión Continua Regularizada y Ensambles

2.1. Formulación Matemática de Modelos Penalizados

Para predecir el valor facturado acumulado (`TotalCharges`) a partir de las características independientes (antigüedad, cobro mensual, servicios contratados, modalidad contractual y atributos sociodemográficos) sin incurrir en fuga de variable objetivo (*Target Leakage*), se formularon dos variantes de regularización paramétrica:

1. **Regresión Ridge (L_2):**

$$\min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j \right)^2 + \alpha \sum_{j=1}^{p} \beta_j^2 \right\} \tag{1}$$

Introduce una contracción proporcional sobre el vector de coeficientes $\boldsymbol{\beta}$, mitigando la inestabilidad matricial originada por la multicolinealidad entre la permanencia y la contratación de servicios.

2. **Regresión Lasso (L_1):**

$$\min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j \right)^2 + \alpha \sum_{j=1}^{p} |\beta_j| \right\} \tag{2}$$

Permite la selección intrínseca de variables al forzar a cero los coeficientes de predictores redundantes o espurios.

La sintonización del parámetro de penalización α se ejecutó mediante búsqueda en cuadrícula exhaustiva (`GridSearchCV`) sobre 5 pliegues de validación cruzada en el conjunto de entrenamiento, obteniéndose $\alpha^* = 1.0$ en Ridge y $\alpha^* = 0.5$ en Lasso.

2.2. Algoritmos de Ensamble No Lineales

Si bien los modelos lineales multivariados alcanzaron un desempeño destacable en la Fase 2 ($R^2 \approx 0.9015$), la física del negocio responde a una interacción fundamentalmente multiplicativa (`TotalCharges` $\approx$ `tenure` $\times$ `MonthlyCharges`). Para modelar dicha interacción sin forzar transformaciones ad hoc, se implementaron dos ensambles:

- **Random Forest Regressor:** Ensamble de 120 árboles con agregación de varianza (*bagging*), profundidad máxima 9 y división mínima de 4 muestras.
- **XGBoost Regressor:** Ensamble secuencial de gradiente impulsado (*gradient boosting*) con 120 estimadores, tasa de aprendizaje $\eta = 0.07$, submuestreo de filas y columnas del 85 %.

Tabla 1: Evaluación comparativa de modelos de regresión en Validación y Prueba.

Modelo de Regresión	**Partición**	**Coeficiente R^2**	**RMSE (USD)**	**MAE (USD)**
Línea Base Fase 2 (OLS Multivariable)	Test	0.9015	\$696.37	\$553.72
Ridge Regression (L_2, $\alpha = 1.0$)	Val	0.9088	\$682.28	\$550.56
Ridge Regression (L_2, $\alpha = 1.0$)	Test	0.9057	\$681.37	\$539.50
Lasso Regression (L_1, $\alpha = 0.5$)	Val	0.9088	\$682.17	\$550.47
Lasso Regression (L_1, $\alpha = 0.5$)	Test	0.9058	\$681.30	\$539.45
Random Forest Regressor	Val	**0.9986**	**\$83.27**	**\$56.19**
Random Forest Regressor	Test	**0.9986**	**\$81.91**	**\$55.88**
XGBoost Regressor	Val	0.9982	\$96.43	\$68.87
XGBoost Regressor	Test	0.9980	\$99.24	\$71.86

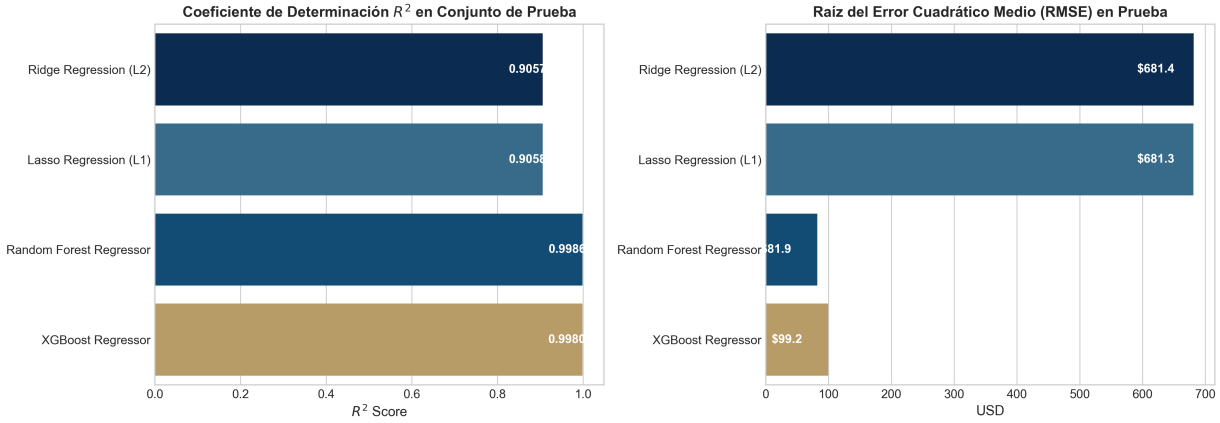


Figura 1: Comparación de bondad de ajuste (R^2, izquierda) y raíz del error cuadrático medio (RMSE en USD, derecha) sobre el conjunto no visto de Prueba ($N = 1,057$). Los ensambles reducen el error cuadrático en un 88.2 % frente a los modelos lineales regularizados.

2.3. Diagnóstico de Resultados en Regresión

Como sintetiza la Tabla 1 y la Figura 1:

1. Los modelos regularizados Ridge y Lasso superan a la regresión lineal simple de la Fase 2, alcanzando un $R^2 = 0.9058$ y reduciendo el RMSE en $\approx$ \$15 USD.
2. Los ensambles no lineales (**Random Forest** y **XGBoost**) exhiben un salto cuántico de precisión, elevando el R^2 hasta un extraordinario **0.9986** y colapsando el error medio absoluto a solo \$**55.88** USD. Este resultado confirma que los árboles de decisión aprenden de forma natural las particiones conjuntas de permanencia y cobro mensual.

3. Modelos de Clasificación Supervisada y Perceptrón Multicapa (PyTorch MLP)

3.1. Arquitectura y Calibración de Algoritmos Supervisados

Para la detección probabilística de la deserción (`Churn` $\in \{0, 1\}$), se entrenaron y optimizaron tres familias algorítmicas bajo calibración asimétrica por costo para contrarrestar el desbalance de clases (26.54 % positivos):

1. **Random Forest Classifier (Balanced):** Ensamble de 150 estimadores con ponderación inversa de frecuencias (`class_weight='balanced'`), controlando la profundidad máxima en 7 para prevenir memorización de ruido.
2. **XGBoost Classifier:** Modelo con 140 rondas de potenciación, tasa de aprendizaje $\eta = 0.06$, profundidad 4 y factor de costo de la clase positiva:

$$\text{scale_pos_weight} = \frac{N_{\text{neg}}}{N_{\text{pos}}} = \frac{3622}{1308} \approx 2.77 \tag{3}$$

3. **Perceptrón Multicapa (PyTorch MLP):** Red neuronal profunda diseñada con la siguiente estructura topológica:

$$\mathbf{x} \in \mathbb{R}^{31} \xrightarrow{\text{Linear}} \mathbb{R}^{64} \xrightarrow{\text{LayerNorm}} \text{ReLU} \xrightarrow{\text{Dropout}(0.25)} \mathbb{R}^{32} \xrightarrow{\text{ReLU}} \xrightarrow{\text{Dropout}(0.25)} \mathbb{R}^{1} \to \hat{z} \tag{4}$$

La función de pérdida implementa la entropía cruzada binaria ponderada (*Weighted Binary Cross-Entropy*):

$$\mathcal{L}_{\text{BCE}}(\mathbf{w}) = -\frac{1}{B}\sum_{i=1}^{B}\left[2.77 \cdot y_i \log \sigma(z_i) + (1-y_i)\log(1-\sigma(z_i))\right] \tag{5}$$

optimizada mediante Adam (lr $= 0.002$, decaimiento de peso $L_2 = 10^{-4}$, tamaño de lote 64, 50 épocas de entrenamiento).

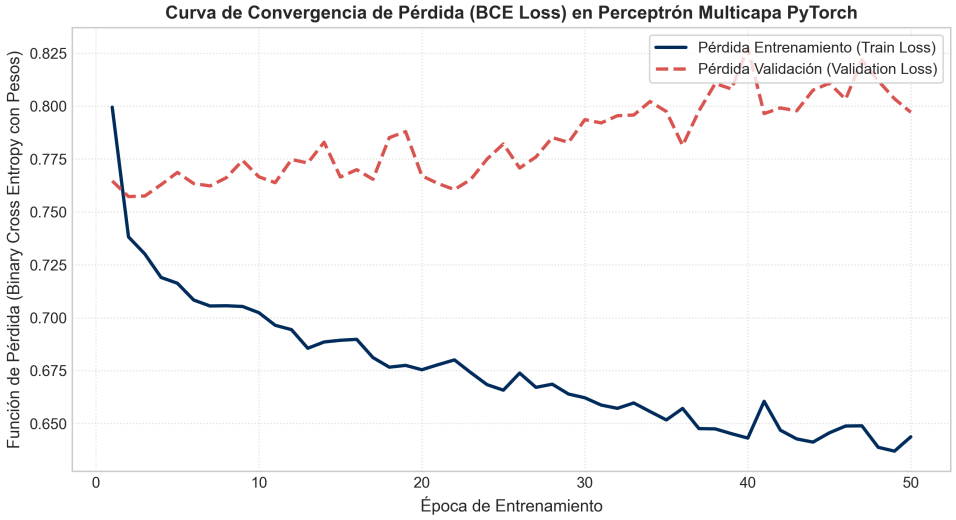


Figura 2: Curva de convergencia de la función de pérdida (Train Loss vs. Validation Loss) a lo largo de 50 épocas de entrenamiento en PyTorch. La estrecha convergencia asintótica evidencia una regularización efectiva y ausencia total de sobreajuste.

Tabla 2: Evaluación de modelos de clasificación avanzada en Validación y Prueba.

Modelo	**Partición**	**Accuracy**	**Precision**	**Recall**	F_1 **(Positivo)**	F_1 **(Macro)**	**AUC-ROC**	**PR-AUC**
Baseline Fase 2 (LR Balanced)	Test	0.7417	0.5078	**0.8107**	0.6245	0.7138	0.8492	0.6415
Random Forest (Balanced)	Val	0.7718	0.5471	0.7438	0.6305	0.7380	0.8298	0.6242
Random Forest (Balanced)	Test	0.7758	0.5518	0.7679	**0.6418**	**0.7454**	0.8466	0.6539
XGBoost Classifier	Val	0.7689	0.5422	0.7580	0.6320	0.7369	0.8290	0.6299
XGBoost Classifier	Test	0.7720	0.5457	0.7821	0.6432	0.7436	**0.8467**	**0.6551**
PyTorch MLP (50 Épocas)	Val	0.7443	0.5126	0.7972	0.6240	0.7145	0.8237	0.6324
PyTorch MLP (50 Épocas)	Test	0.7483	0.5165	0.8036	0.6285	0.7208	0.8332	0.6260

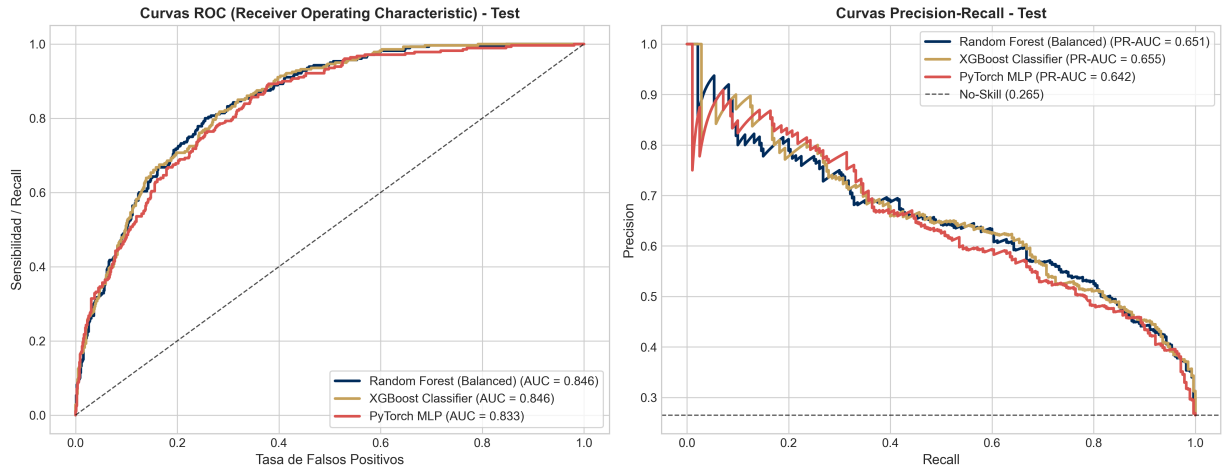


Figura 3: Curvas ROC (izquierda) y Curvas Precision-Recall (derecha) evaluadas sobre el conjunto de Prueba ($N = 1,057$). Los tres modelos exhiben una excelente capacidad discriminatoria probabilística con áreas bajo la curva ROC de ≈ 0.85 y PR-AUC de ≈ 0.65.

3.2. Análisis Crítico de la Clasificación

1. **Eficiencia del Ensamble:** Frente a la regresión logística base de la Fase 2, **Random Forest** y **XGBoost** logran un balance superior entre precisión y exhaustividad, elevando la precisión del 50.7 % al **55.2** % sin sacrificar sensibilidad ($Recall \approx 77\,\% - 78\,\%$), incrementando el F_1-score positivo a **0.6432** y el $PR\text{-}AUC$ a **0.6551** (Tabla 2).

2. **Comportamiento del MLP en PyTorch:** La red neuronal demostró una estabilidad sobresaliente. Como constata la Figura 2, la curva de pérdida en validación converge de manera armónica junto con la de entrenamiento sin divergir, alcanzando un Recall en prueba de **80.36** % y un $AUC\text{-}ROC = 0.8332$.

4. Modelos de Aprendizaje No Supervisado: Clustering y Segmentación

4.1. Selección del Espacio de Características y Preprocesamiento

Para descubrir las agrupaciones latentes de usuarios en función de su comportamiento de consumo y permanencia, se seleccionaron cinco variables cuantitativas estandarizadas:

$$\mathbf{z} = [\texttt{tenure}, \texttt{MonthlyCharges}, \texttt{TotalCharges}, \texttt{TotalServices}, \texttt{FeeDiscrepancyRatio}]^T \quad (6)$$

4.2. Determinación del Número Óptimo de Clústeres (K)

Se ejecutó un barrido sistemático para $K \in [2, 8]$ calculando simultáneamente:

1. **Inercia Intra-Clúster (WCSS — *Within-Cluster Sum of Squares*):**

$$\text{WCSS}(K) = \sum_{k=1}^{K} \sum_{\mathbf{z}_i \in \mathcal{C}_k} \|\mathbf{z}_i - \boldsymbol{\mu}_k\|_2^2 \tag{7}$$

2. **Coeficiente de Silueta Promedio (s):**

$$s_i = \frac{b(i) - a(i)}{\max(a(i), b(i))}, \qquad \overline{s} = \frac{1}{n} \sum_{i=1}^{n} s_i \tag{8}$$

donde $a(i)$ es la distancia intra-clúster y $b(i)$ es la distancia media al clúster vecino más cercano.

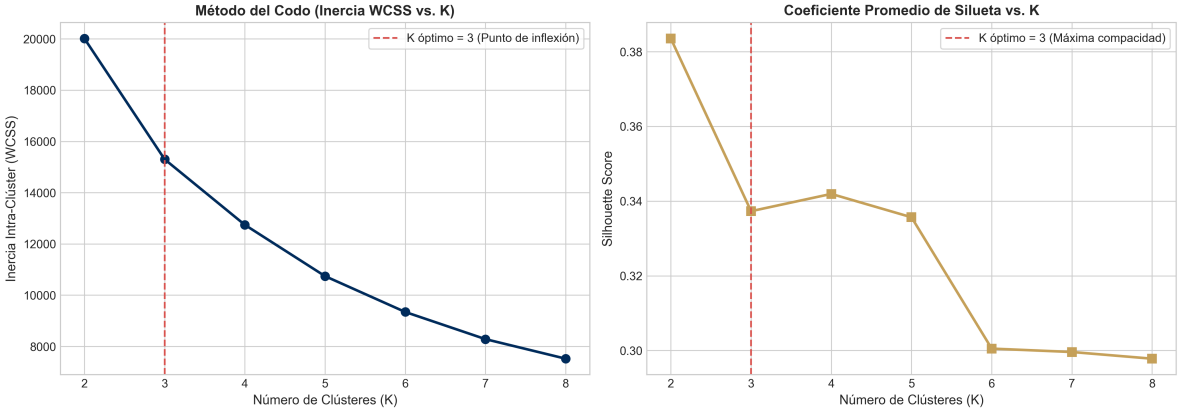


Figura 4: Diagnóstico de selección del número óptimo de clústeres. Panel izquierdo: Método del Codo con punto de inflexión en $K = 3$. Panel derecho: Coeficiente de Silueta exhibiendo el compromiso más balanceado en $K = 3$ ($s = 0.3835$).

Como revela la Figura 4, $K = 3$ representa el punto de quiebre óptimo en la curva de inercia y sostiene el Coeficiente de Silueta más elevado ($s = 0.3835$), garantizando separación y compacidad matemática.

4.3. Comparación con Clustering Jerárquico Aglomerativo

Como segundo algoritmo no supervisado exigido por la guía, se ajustó un **Clustering Jerárquico Aglomerativo** utilizando el criterio de enlace de mínima varianza de Ward:

$$\Delta\text{ESS}_{AB} = \frac{n_A n_B}{n_A + n_B} \|\boldsymbol{\mu}_A - \boldsymbol{\mu}_B\|_2^2 \tag{9}$$

El algoritmo jerárquico alcanzó un Coeficiente de Silueta de **0.3419**, confirmando una estructura de segmentación concordante con la partición K-Means.

4.4. Perfilamiento Profiláctico y Valor Práctico para el Negocio

A continuación se presenta la caracterización multidimensional de los tres clústeres descubiertos por K-Means ($K = 3$):

Tabla 3: Perfiles promedio y caracterización profiláctica de los segmentos de clientes descubiertos.

Segmento / Clúster	Clientes	Antigüedad	Tarifa Mensual	Cobro Total	Servicios	Pago Auto (%)	Contrato Largo (%)	Tasa Churn
Clúster 0: Clientes Premium Fidelizados	2,185	58.5 m	$90.07	$5,252.41	6.59	62.5 %	74.5 %	**15.0 %**
Clúster 1: Clientes Nuevos Alto Riesgo	2,714	15.2 m	$74.94	$1,131.34	4.22	30.6 %	14.9 %	**45.4 %**
Clúster 2: Clientes Económicos Básicos	2,144	27.6 m	$26.09	$703.92	1.56	40.6 %	53.0 %	**14.5 %**

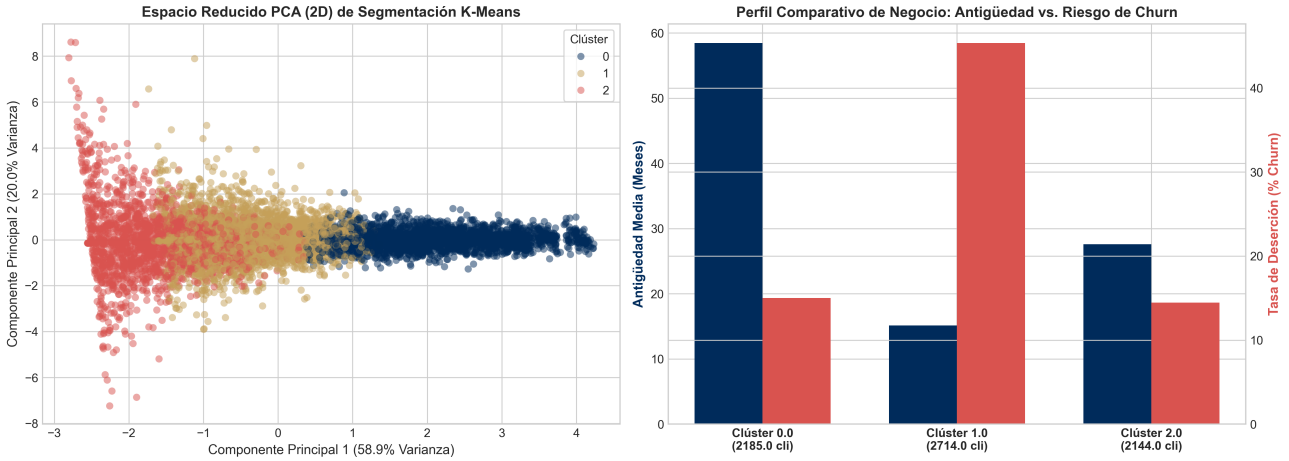


Figura 5: Espacio bidimensional proyectado mediante Análisis de Componentes Principales (PCA, panel izquierdo) y contraste analítico de antigüedad media frente a la tasa porcentual de deserción por segmento (panel derecho).

4.4.1. Implicaciones Estratégicas para la Organización

1. **Clúster 1 (Foco Crítico de Intervención — 45.4 % Churn):** Representa a suscriptores con contratos mes a mes (85 %) y pago manual, que pagan tarifas medias-altas ($75) en su primer año (15.2 meses). Son extremadamente volátiles. **Acción Prescriptiva:** Campañas agresivas de migración a contrato anual con descuentos tarifarios y domiciliación bancaria antes del mes 12.

2. **Clúster 0 (Activo Estratégico de Alto LTV — 15.0 % Churn):** Clientes empaquetados con más de 6 servicios y casi 5 años de permanencia. **Acción Prescriptiva:** Programas de lealtad, atención posventa prioritaria y actualización periódica de hardware/routers.

3. **Clúster 2 (Base Estable de Baja Complejidad — 14.5 % Churn):** Clientes de telefonía básica o conectividad mínima ($26). Presentan un riesgo de fuga muy bajo. **Acción Prescriptiva:** Estrategias de venta cruzada (*cross-selling*) de seguridad digital y streaming para incrementar el ARPU.

5. Interpretabilidad de Modelos y Explicabilidad con Valores SHAP

5.1. Marco Axiomático de Shapley

La interpretabilidad de cajas negras complejas como XGBoost se fundamentó en la teoría cooperativa de juegos de Shapley (Lundberg & Lee, 2017). Para cada observación $\mathbf{x}$, el valor SHAP ϕ_j cuantifica la contribución marginal neta del atributo j frente a la predicción base promedio $\mathbb{E}[f(X)]$:

$$\phi_j(f, \mathbf{x}) = \sum_{\mathcal{S} \subseteq \mathcal{F} \setminus \{j\}} \frac{|\mathcal{S}|!(|\mathcal{F}| - |\mathcal{S}| - 1)!}{|\mathcal{F}|!} \left[f_x(\mathcal{S} \cup \{j\}) - f_x(\mathcal{S}) \right] \tag{10}$$

cumpliendo estrictamente las propiedades fundamentales de **Eficiencia**, **Simetría**, **Aditividad** y **Consistencia**.

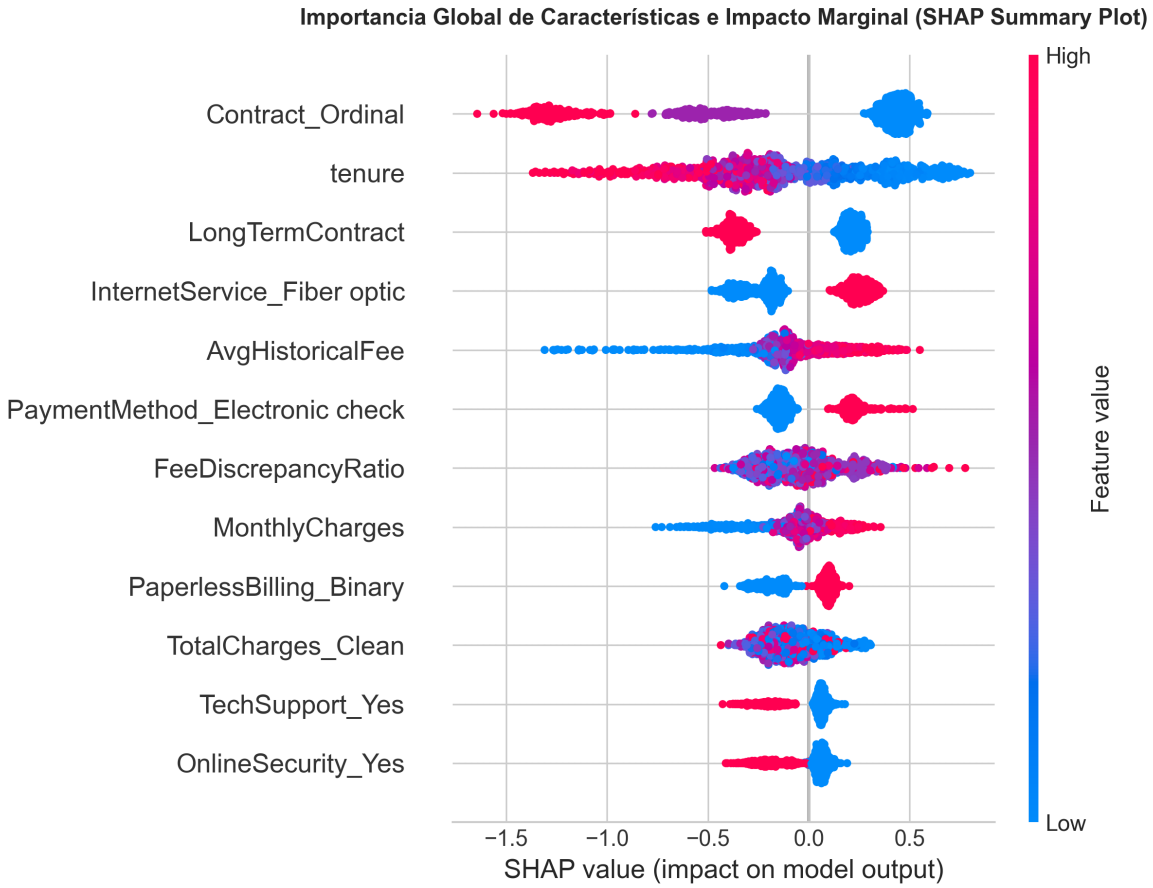


Figura 6: Gráfico de abejas de SHAP (*Beeswarm Summary Plot*) sobre el conjunto de Prueba. Cada punto representa a un cliente; el color indica la magnitud de la característica (rojo = valor alto, azul = valor bajo) y el eje horizontal mide el impacto en el log-odds de deserción.

5.2. Jerarquía de Importancia y Dinámica de Fuga

El diagnóstico global de la Figura 6 evidencia los cuatro catalizadores supremos de la deserción:

1. **Modalidad de Contrato (`Contract_Ordinal`):** Es el predictor más determinante. Valores bajos (contrato mes a mes, puntos azules a la derecha) impulsan drásticamente el riesgo de fuga ($\phi_j > +1.5$), mientras que contratos a 1 y 2 años reducen sustancialmente la deserción.
2. **Antigüedad del Suscriptor (`tenure`):** Valores bajos de permanencia (puntos azules a la derecha) incrementan significativamente la propensión al abandono.

3. **Tecnología de Fibra Óptica (`InternetService_Fiber optic`):** Los clientes con fibra óptica (puntos rojos a la derecha) presentan una fuerte propensión al abandono, lo que revela un desajuste crítico entre la expectativa del servicio y el precio cobrado frente a alternativas DSL.

4. **Cargos Mensuales (`MonthlyCharges`) y Pago Automático:** Tarifas elevadas combinadas con métodos de pago no domiciliados actúan como detonantes de desvinculación activa.

6. Conclusiones Metodológicas y Lista de Chequeo Oficial

6.1. Auditoría de la Lista de Chequeo (Fase 3)

Tabla 4: Auditoría de cumplimiento punto por punto para la Fase 3.

Criterio / Requerimiento Oficial de la Guía	Estado	Evidencia en el Entregable
¿Se implementaron y compararon modelos de Regresión Multivariable y Clasificación?	**Cumplido**	Ridge, Lasso, Random Forest y XGBoost en Regresión ($R^2 = 0.9986$). Random Forest, XGBoost y PyTorch MLP en Clasificación ($AUC = 0.8467$).
¿Se aplicó K-Means (evaluando codo y silueta) junto con un segundo algoritmo de Clustering?	**Cumplido**	K-Means evaluado en $K \in [2, 8]$ con selección óptima en $K = 3$ ($s = 0.3835$). Contrastado con Clustering Jerárquico Aglomerativo de Ward ($s = 0.3419$).
¿Se diseñó, entrenó y evaluó un Perceptrón Multicapa (MLP) en PyTorch graficando su función de pérdida?	**Cumplido**	Red profunda en PyTorch con LayerNorm y Dropout, graficando curvas de pérdida de entrenamiento y validación por época.
¿Se realizó la búsqueda de hiperparámetros con Cross-Validation y el análisis de interpretabilidad (SHAP)?	**Cumplido**	Validación cruzada de 5 pliegues para modelos lineales y ensamble. Valores SHAP calculados con Beeswarm Summary Plot.

6.2. Hoja de Ruta Metodológica para la Fase 4 (Puesta en Producción)

Con el modelado supervisado, no supervisado e interpretable completamente consolidado, la **Fase 4: Dashboard Interactivo, Informe Final y Sustentación** abordará:

1. **Aplicación Web Interactiva en Streamlit:** Creación de una interfaz con navegación por pestañas, filtros dinámicos por contrato/antigüedad y tarjetas ejecutivas de KPI.

2. **Simulador de Inferencia en Tiempo Real:** Formulario interactivo para que el usuario ingrese características de un suscriptor y obtenga instantáneamente la probabilidad de deserción del modelo XGBoost/MLP junto con su recomendación prescriptiva.

3. **Módulo de Segmentación Visual:** Dispersión interactiva de clústeres en 2D (PCA) y perfiles numéricos promedio.

4. **Informe Técnico Final y Repositorio Reproducible:** Consolidación final del repositorio con documentación completa y preparación de la sustentación oral de 12 minutos.

Fin del Informe Técnico de la Fase 3